

古代玻璃制品的成分分析与鉴别

赵宇翔 李传浩 马文杰

1120240258 1120240023 1120240005

报告人：**赵宇翔**

2026 年 9 月 17 日

研究背景

- 古代玻璃分两类助熔剂体系：高钾玻璃、铅钡玻璃
- 文物埋藏中发生风化：元素交换改变成分占比，干扰类型识别
- 数据为成分数据：各成分比例累加和应约为 100%，题目规定在 85% ~ 105% 内视为有效

问题

- ① 风化与类型/纹饰/颜色的关系；风化前后化学成分统计规律；预测风化前成分
- ② 高钾、铅钡的分类规律；两类内部亚类划分；合理性与敏感性分析

模型假设

- ① 未风化文物以及文物未风化部位的检测成分可以近似作为玻璃风化前的原始组分
- ② 高钾、铅钡玻璃类别在风化前后维持不变
- ③ 未检出成分视作低于仪器检出限而非随机缺失
- ④ 同一类型玻璃发生风化时，由于在化学反应中涉及的化学成分是成比例的，各成分迁移、反应的比例具备相对稳定性，可依托各成分相对于 SiO_2 的反应比例描述风化行为
- ⑤ 不同文物样本相互独立，同一文物的多个采样点经聚合后视为单个独立样本，可代表该文物整体成分特征

参考文献：

- 侯兴汉, 彭悌珊, 于波, 等. 基于 SVR 插补高缺失率的地下水水质监测数据插补研究 [J]. 安全与环境学报, 2026, 26(6): 2465-2474.
- 钱鸿羽, 岳思情, 许雷, 等. 基于多元线性回归的古代玻璃体系判别方法 [J]. 甘肃科技, 2024, 40(2): 56-61.

处理流程

- 累加和有效性筛选:

$$S_i = \sum_{d=1}^D x_{id}$$

其中 S_i 为第 i 个采样点的成分累加和, x_{id} 为该采样点第 d 种成分的质量分数, D 为成分总数

85% ~ 105% 视为有效, 剔除 2 条

- 定义缺失率:

$$\rho_d = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{x_{id} \text{ 未检出}\} \times 100\%$$

其中 ρ_d 为第 d 种成分的缺失率, n 为样本总数, $\mathbf{1}\{\cdot\}$ 为示性函数。将 14 种成分划分为高、中、低缺失三档, 区分检出限缺失与可插补缺失, 高缺失成分仅保留二值检出特征, 对中、低缺失考虑插补

- SVR 插补: 仅对拟合 R^2 高的 K_2O 、 PbO 、 BaO 三列插补, 其余只保留二值检出特征 (R^2 为决定系数, 取值 0 ~ 1, 越接近 1 说明预测得越准)
- 同文物多采样点聚合取均值, 得 56 组有效文物级样本

参考文献: 侯兴汉, 彭悌珊, 于波, 等. 基于 SVR 插补高缺失率的地下水水质监测数据插补研究 [J]. 安全与环境学报, 2026, 26(6): 2465-2474.

问题一：风化与类型/纹饰/颜色的关系

卡方独立性检验

原假设与备择假设：

$$H_0 : \text{属性与表面风化相互独立}, \quad H_1 : \text{二者不独立}.$$

检验属性（类型/纹饰/颜色）与风化是否独立：

$$\chi^2 = \sum_{\ell, c} \frac{(n_{\ell c} - E_{\ell c})^2}{E_{\ell c}}, \quad E_{\ell c} = \frac{n_{\ell \cdot} \cdot n_{\cdot c}}{n}$$

其中 χ^2 为卡方统计量， ℓ 为属性类别下标 ($\ell = 1, \dots, L$)， c 为风化状态下标 ($c = 1$ 无风化、 $c = 2$ 风化)， $n_{\ell c}$ 为第 ℓ 类属性、第 c 类风化的观测频数， $E_{\ell c}$ 为对应格的期望频数， $n_{\ell \cdot}$ 、 $n_{\cdot c}$ 分别为行合计与列合计， n 为样本总数。 χ^2 越大表示假设越不可能成立

$P = \Pr(\chi^2(\nu) \geq \chi_{\text{obs}}^2)$ ， χ_{obs}^2 为观测样本的卡方统计量， $P < 0.05$ 认为显著相关。

蒙特卡洛置换检验

当列联表存在**零频或期望频数过小** (< 5) 时，卡方近似失效。将风化标签随机重排 N_{perm} 次、每次重算卡方统计量，置换检验 P 值为

$$P_{\text{perm}} = \frac{\sum_{t=1}^{N_{\text{perm}}} \mathbf{1}\{\chi_t^2 \geq \chi_{\text{obs}}^2\} + 1}{N_{\text{perm}} + 1}$$

其中 P_{perm} 为置换检验得到的 P 值， $N_{\text{perm}} = 5000$ 为随机重排次数， t 为重排次数的下标， χ_t^2 为第 t 次重排后重算的卡方统计量， χ_{obs}^2 为观测样本的卡方统计量。分子分母同加 1 以避免 $P = 0$ 的伪精确

参考文献：彭丽红，王颖梁，唐玥，等. 古代玻璃文物鉴别和分类问题的统计分析 [J]. 黑龙江科学, 2024, 15(24): 102-105

卡方独立性检验与蒙特卡洛置换检验

输入：某属性列（类型/纹饰/颜色系）与表面风化列；置换次数 $N_{\text{perm}} = 5000$ 。

输出：卡方统计量 χ^2 、 P 值、是否采用置换检验。

流程：

- ① 以属性为行、风化状态为列构造列联表，记录观测频数。
- ② 计算各格的期望频数，并求卡方统计量 $\chi^2 = \sum_{\ell=1}^L \sum_{c=1}^2 \frac{(n_{\ell c} - E_{\ell c})^2}{E_{\ell c}}$
- ③ 判定近似条件：若所有期望频数均 ≥ 5 ，采用卡方近似，直接取卡方检验返回的 P 值。
- ④ 否则改用蒙特卡洛置换检验：
 - 固定属性列不变，用固定随机种子将风化标签随机重排 5000 次；
 - 每次重排后重新构造列联表并计算卡方统计量；
 - 统计重排卡方值 $\geq$ 观测卡方值的次数；
 - 计算 $P_{\text{perm}} = \frac{\sum_{t=1}^{N_{\text{perm}}} 1\{\chi_t^2 \geq \chi_{\text{obs}}^2\} + 1}{N_{\text{perm}} + 1}$
- ⑤ 返回统计量、 P 值与检验方式
- ⑥ 结论判定： $P < 0.05$ 记显著相关，否则不显著。

为刻画关联方向并对检验结论交叉验证，进一步计算 Spearman 秩相关 ρ 与 Kendall 秩相关 τ 。 ρ 与 τ 均取值于 $[-1, 1]$ ，其正负与大小反映关联方向与强弱

结果

表 1: 表面风化与玻璃类型、纹饰、颜色关联性的检验结果

属性	卡方统计量	P 值	Spearman ρ	Kendall τ	结论
类型	5.452	0.0195	-0.344**	-0.344**	显著相关
纹饰	4.957	0.106*	+0.037	+0.036	不显著
颜色	2.126	0.659*	-0.020	-0.020	不显著

注：* 为蒙特卡洛置换检验 p 值；** 表示 $p < 0.01$ 。

表面风化与玻璃类型显著相关，风化与纹饰、颜色不存在显著关联

问题一：风化前后化学成分统计规律

Mann-Whitney U 检验

分别对一类玻璃的一种成分做一次检验，比较这个成分在“未风化组”和“风化组”上是不是一个水平。

原假设与备择假设：

$$H_0 : \text{两组含量分布相同}, \quad H_1 : \text{两组含量分布不同}.$$

成分含量偏离正态分布，故用非参数秩和检验比较风化/未风化两组的分布差异，定义 Mann-Whitney 统计量：

$$U = n_0 n_1 + \frac{n_1(n_1 + 1)}{2} - R_1$$

其中 n_0 、 n_1 分别为无风化组与风化组的有效样本数， R_1 为风化组的秩和。 U 的含义为风化组中每个观测小于无风化组观测的次数之和

$P = \Pr_{H_0} \left(\left| U - \frac{n_0 n_1}{2} \right| \geq \left| U_{\text{obs}} - \frac{n_0 n_1}{2} \right| \right)$ ，在 H_0 下， U 的分布仅取决于 n_0 、 n_1 ，其中小样本取精确分布，大样本可用正态分布近似， $P < 0.05$ 认为差异显著

结果

使用 Cohen's d 效应量刻画差异大小， $d > 0$ 表示风化后含量升高、 $d < 0$ 表示下降

高钾：SiO₂ 由 66.69% → 93.96% ($P < 0.001$, $d = 4.80$)，K₂O、CaO、Al₂O₃、Fe₂O₃ 显著下降——硅富集、助熔组分流失

铅钡：SiO₂ 由 54.93% → 27.73% ($P < 0.001$, $d = -2.45$)，PbO、CaO、P₂O₅ 显著升高——硅流失、重金属富集

参考文献：钱鸿羽，岳思情，许雷，等. 基于多元线性回归的古代玻璃体系判别方法 [J]. 甘肃科技, 2024, 40(2): 56-61.

Mann-Whitney U 检验

输入：文物级主表，按（玻璃类型，表面风化情况）分组。

输出：每种成分在对应组里的均值、 P 值、变化方向与显著性。

流程：

- ① 对高钾、铅钡两类玻璃分别处理：取出风化组与无风化组样本。
- ② 对 14 种成分逐一检验：
 - 分别取未分化组和分化组两组的有效检出值；
 - 任一组有效样本数 < 2 则跳过该成分；
 - 将两组观测合并排序取秩，计算风化组的秩和，进而得到 U 统计量
$$U = n_0 n_1 + \frac{n_1(n_1+1)}{2} - R_1;$$
 - 求 P 值（小样本精确分布/大样本正态近似）；
 - 计算两组均值并标记变化方向（风化组均值更大记上升，否则下降）；
 - $P < 0.05$ 记显著。
- ③ 汇总所有检验结果

问题一：风化前成分预测

思路

- ① 风化程度多元回归：按风化状态给每个采样点赋风化程度值
- ② 估计反应比例：计算各成分相对 SiO_2 的迁移比例
- ③ 反推风化前成分：由实测含量按反应比例扣减风化损耗，还原到风化前状态

参考文献：

- 钱鸿羽, 岳思情, 许雷, 等. 基于多元线性回归的古代玻璃体系判别方法 [J]. 甘肃科技, 2024, 40(2): 56-61.
- 熊强, 张瀚文, 张宏俊, 等. 多元数学建模分析古风化玻璃成分研究 [J]. 西北民族大学学报 (自然科学版), 2025, 46(4): 7-22.

问题二：分类规律

方法及作用

- Spearman 秩相关 ρ_d : 刻画类型与各成分的关联方向, $\rho_d > 0$ 表示该成分随铅钡倾向升高, $\rho_d < 0$ 表示随高钾倾向升高
- 随机森林特征重要性: 筛选分类核心成分、实现降维
- 逻辑回归: 输出类别概率, 判别系数为正表示促进判别为铅钡、为负表示促进判别为高钾
- CART 决策树: 输出 “ $PbO \leq 5.46$ 判高钾、 $PbO > 5.46$ 判铅钡” 的可读规则

参考文献:

- 刘振文, 何彭. 基于随机森林及 K-means++ 对玻璃文物的成分分析与鉴别 [J]. 长春工业大学学报, 2025, 46(6): 545-551.
- 张星园, 孟怡辰, 罗建龙, 等. 基于 CatBoost 的玻璃成分与风化关系实证探究 [J]. 玻璃, 2023(8): 15-23.
- 熊强, 张瀚文, 张宏俊, 等. 多元数学建模分析古风化玻璃成分研究 [J]. 西北民族大学学报 (自然科学版), 2025, 46(4): 7-22.

表 2: 核心成分的 Spearman 相关、随机森林特征重要性与逻辑回归判别系数

成分	Spearman ρ	RF 特征重要性	Logistic 判别系数
PbO	+0.786	0.273	+1.221
BaO	+0.763	0.241	+0.851
SiO ₂	-0.680	0.140	-1.151
K ₂ O	-0.554	0.105	-0.833
SrO	+0.613	0.096	+0.598
CaO	-0.264	0.036	-0.627
Al ₂ O ₃	-0.215	0.026	+0.252
CuO	-0.235	0.025	-0.586

注：Spearman ρ 以类型编码（高钾 = 0、铅钡 = 1）计算；判别系数为正促进判为铅钡、为负促进判为高钾。




图 1: 14 种成分的随机森林特征重要性

问题二：亚类划分

K-means 聚类

对每类玻璃取前 7 位核心成分（标准化后）聚类，目标函数为簇内离差平方和：

$$SSE = J_K = \sum_{k=1}^K \sum_{i \in \mathcal{G}_k} \sum_{d \in \mathcal{Q}} (z_{id} - \mu_{kd})^2$$

其中 J_K 为簇内离差平方和（目标函数）， K 为聚类数， $\mathcal{G}_k$ 为第 k 个簇的样本集合， $\mathcal{Q}$ 为核心成分指标集， $\mathcal{Q} = \{\text{PbO}, \text{BaO}, \text{SiO}_2, \text{K}_2\text{O}, \text{SrO}, \text{CaO}, \text{Al}_2\text{O}_3\}$ ， z_{id} 为第 i 个样本第 d 种核心成分的标准化值， μ_{kd} 为第 k 个簇在第 d 种成分上的质心

K-means 聚类算法流程

- 1 初始化：先随便放 K 个初始质心
- 2 分配：每个样本分给离它最近的质心
- 3 更新：按簇内样本重新算均值，质心挪到簇的中心
- 4 重复 2、3，直到质心不再变化

Remark

局限：每一步都让 J_K 不增，所以算法保证收敛，但只保证收敛到“局部最优”，不保证全局最优

K-means 聚类

输入：样本 $\{z_1, z_2, \dots, z_n\}$ ($z_i \in \mathbb{R}^q$), 类数 K , 终止阈值 $\varepsilon > 0$.

- 1 **初始化：**选取 K 个初始质心 $\mu_1^{(0)}, \mu_2^{(0)}, \dots, \mu_K^{(0)}$
- 2 **分配：**对每个样本 z_i , 将其归入离它最近的质心所在簇

$$\mathcal{G}_k^{(t+1)} = \left\{ i : \|z_i - \mu_k^{(t)}\|^2 \leq \|z_i - \mu_{k'}^{(t)}\|^2, \forall k' \neq k \right\}, \quad k = 1, 2, \dots, K.$$

- 3 **更新：**将每个簇的质心更新为该簇所有样本的均值

$$\mu_k^{(t+1)} = \frac{1}{|\mathcal{G}_k^{(t+1)}|} \sum_{i \in \mathcal{G}_k^{(t+1)}} z_i, \quad k = 1, 2, \dots, K.$$

- 4 **终止判断：**若 $\max_k \|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \varepsilon$ 或各簇的成员集合不再变化, 则停止迭代并输出划分 $\{\mathcal{G}_1, \dots, \mathcal{G}_K\}$ 与质心 $\{\mu_1, \dots, \mu_K\}$; 否则令 $t \leftarrow t + 1$, 返回步骤 2.

问题二：亚类划分

K-means++

K-means++ 聚类在 K-means 聚类的基础上，改进初始质心选取：依次挑选初始质心，候选样本以与已选质心最短距离的平方成正比的概率被选中，以降低初始值对局部最优的影响

参考文献：刘振文, 何彭. 基于随机森林及 K-means++ 对玻璃文物的成分分析与鉴别 [J]. 长春工业大学学报, 2025, 46(6): 545-551.

K-means++

输入：样本 $\{z_1, z_2, \dots, z_n\}$, 类数 K ; 记已选质心集合为 $\mathcal{C}$ 。

- ① 从样本集中等概率随机选取第一个初始质心：

$$\mu_{(1)} \sim \text{Uniform}\{z_1, z_2, \dots, z_n\}, \quad \mathcal{C} \leftarrow \{\mu_{(1)}\}.$$

- ② 对每个样本 z_i , 计算它到已选质心集合的最近距离

$$D(z_i) = \min_{\mu \in \mathcal{C}} \|z_i - \mu\|.$$

- ③ 以正比于 $D(z_i)^2$ 的概率抽取下一个初始质心：

$$\Pr(\mu_{(m+1)} = z_i) = \frac{D(z_i)^2}{\sum_{j=1}^n D(z_j)^2}, \quad i = 1, 2, \dots, n.$$

- ④ 更新 $\mathcal{C} \leftarrow \mathcal{C} \cup \{\mu_{(m+1)}\}$; 若 $|\mathcal{C}| < K$, 则返回步骤 2 继续选取; 否则输出 K 个初始质心, 转入 K-means 算法步骤 2 开始迭代。

Definition (轮廓系数)

样本 i 的轮廓系数

$$q_i = \frac{\beta_i - \alpha_i}{\max(\alpha_i, \beta_i)},$$

其中 α_i 为 i 与同簇其余样本的平均距离、 β_i 为 i 到最近异簇的平均距离

$$\alpha_i = \frac{1}{|\mathcal{G}_{k(i)}| - 1} \sum_{\substack{j \in \mathcal{G}_{k(i)} \\ j \neq i}} d(\mathbf{x}_i, \mathbf{x}_j)$$

$$\beta_i = \min_{\ell \neq k(i)} \left[\frac{1}{|\mathcal{G}_\ell|} \sum_{j \in \mathcal{G}_\ell} d(\mathbf{x}_i, \mathbf{x}_j) \right]$$

取平均轮廓 $\bar{q} = \frac{1}{n} \sum_{i=1}^n q_i$ 最大所对应的 K

参考文献：彭丽红, 王颖梁, 唐玥, 等. 古代玻璃文物鉴别和分类问题的统计分析 [J]. 黑龙江科学, 2024, 15(24): 102-105.

K-means++ 聚类评估 (SSE与轮廓系数随K的变化)




图 3: 两类玻璃的轮廓系数与 SSE 随类数变化


定义簇 k 在成分 d 上的标准化均值偏移

$$t_{kd} = \frac{\bar{C}_{k,d} - \bar{C}_d}{s_d}$$

其中 $\bar{C}_{k,d}$ 为簇 k 在成分 d 上的均值、 $\bar{C}_d$ 为同类型全体样本在成分 d 上的均值；以同类型样本标准差 s_d 为单位度量， $|t_{kd}|$ 明显大于 1 的成分即该亚类的主导差异成分

参考文献：彭丽红, 王颖梁, 唐玥, 等. 古代玻璃文物鉴别和分类问题的统计分析 [J]. 黑龙江科学, 2024, 15(24): 102-105.

图6-2 高钾、铅钡玻璃亚类划分 (核心成分PCA投影, ×为亚类质心)



问题二：敏感性分析

方法及作用

- ARI (调整兰德指数): 度量扰动前后两次划分的一致程度, ARI 越接近 1, 说明两划分越一致、结构越稳健
- 乘性高斯扰动 $\pm 5\%$ / $\pm 10\%$ 并重复 100 次: 检验亚类结构对成分测量误差是否稳健

结果

高钾: ARI 0.981/0.939, 结构稳定; 铅钡: ARI 0.790/0.759, 中等稳定

建模方法的优缺点

优点

- 未检出按检出限缺失处理，仅对 R^2 较高的 K_2O 、 PbO 、 BaO 做 SVR 插补、其余保留二值检出特征，避免无效插补引入畸变
- 多方法互证、可解释：检验兼用非参数检验与效应量；分类由相关分析、随机森林、逻辑回归、浅决策树相互印证
- 使用 K-means++ 聚类改进初始质心的选取

缺点

- 线性模型局限：逻辑回归、多元回归依赖线性结构与近似正态假设，成分间存在共线性且样本量小，回归系数可能不稳定，当判别边界为非线性时表达能力有限
- 样本仅 56 件，且来自有限的考古发现，结论向更广泛的古玻璃总体外推需谨慎

- ① 彭丽红, 王颖梁, 唐玥, 等. 古代玻璃文物鉴别和分类问题的统计分析 [J]. 黑龙江科学, 2024, 15(24): 102-105.
- ② 侯兴汉, 彭悌珊, 于波, 等. 基于 SVR 插补高缺失率的地下水水质监测数据插补研究 [J]. 安全与环境学报, 2026, 26(6): 2465-2474.
- ③ 钱鸿羽, 岳思情, 许雷, 等. 基于多元线性回归的古代玻璃体系判别方法 [J]. 甘肃科技, 2024, 40(2): 56-61.
- ④ 熊强, 张瀚文, 张宏俊, 等. 多元数学建模分析古风化玻璃成分研究 [J]. 西北民族大学学报 (自然科学版), 2025, 46(4): 7-22.
- ⑤ 刘振文, 何彭. 基于随机森林及 K-means++ 对玻璃文物的成分分析与鉴别 [J]. 长春工业大学学报, 2025, 46(6): 545-551.
- ⑥ 张星园, 孟怡辰, 罗建龙, 等. 基于 CatBoost 的玻璃成分与风化关系实证探究 [J]. 玻璃, 2023(8): 15-23.
- ⑦ 范一苇. 深度学习的统计学习框架 (课程讲义) [Z]. 北京理工大学. 第 1-4 讲; K 折交叉验证与数据泄漏见第 3 讲, 线性神经网络见第 4 讲. 2026.

Thanks!