

基于CatBoost的玻璃成分与风化关系实证探究

张星园¹ 孟怡辰¹ 罗建龙¹ 李言^{1,2}

(1. 华北理工大学 唐山 063210; 2. 河北省数据科学与应用重点实验室 唐山 063210)

摘要 高钾玻璃和铅钡玻璃的化学成分含量和物理属性不同,研究玻璃文物样品的类型对文物的保存和探索有着重要价值。为了精确分类玻璃文物样品类型,通过综合相关性分析研究两种玻璃的分类规律,发现玻璃类型和二氧化硅、氧化钾、氧化铅和氧化钡的相关系数可达到0.7,得知高钾玻璃中氧化硅和氧化钾含量较高,铅钡玻璃中氧化钡和氧化铅含量较高。结合样品的分类规律,以玻璃文物样品的化学成分以及表面风化情况作为特征参数建立CatBoost分类模型,并得到准确率为97%,召回率为95.9%,F1值为92.4%的模型效果,同时利用关联性和差异性分析进行模型验证,为考古工作者快速区分玻璃文物样品类型提供理论指导依据。

关键词 CatBoost算法; 玻璃文物样品分类; 综合相关性分析; 差异性分析

中图分类号: TP18 文献标识码: A 文章编号: 1003-1987(2023)08-0015-09

An Empirical Study on the Relationship between Glass Composition and Weathering Based on CatBoost

ZHANG Xingyuan¹, MENG Yichen¹, LUO Jianlong¹, LI Yan^{1,2}

(1. North China University of Science and Technology, Tangshan 063210, China;

2. Hebei Key Laboratory of Data Science and Application, Tangshan 063210, China)

Abstract: High-potassium glass and lead-barium glass have different chemical compositions and physical properties. It is valuable to study the types of glass cultural relics for their preservation and exploration. For accurately classifying the types, the classification law of the two types of glass was studied through comprehensive correlation analysis. It was found that the correlation coefficient between the types of glass and silica, potassium oxide, lead oxide and barium oxide could reach 0.7 and the content of silica and potassium oxide were higher in the high potassium glass, and the content of barium oxide and lead oxide were higher in the lead barium glass. Combining the classification laws, the CatBoost classification model was established with the chemical compositions of glass artifact samples and surface weathering condition as characteristic parameters. The model effect with 97% accuracy, 95.9% recall and 92.4% F1 value was obtained, and correlation and difference analysis were used for model validation. It provides theoretical guidance basis for archaeologists to quickly distinguish glass artifact sample types.

Key Words: CatBoost algorithm, glass artifact samples classification, comprehensive correlation analysis, variance analysis

0 引言

丝绸之路^[1]是古代中西方文化交流的通道,其中玻璃是早期贸易往来的宝贵物证。铅钡玻璃在烧制过程中加入铅矿石作为助熔剂^[2],其氧化

铅、氧化钡的含量较高,而钾玻璃是以含钾量高的物质如草木灰作为助熔剂烧制而成的。可以将古代玻璃类型划分为高钾玻璃和铅钡玻璃。

玻璃文物样品的化学成分极大的影响分类结果,为了精确测定玻璃文物样品的化学成分,国内学

作者简介: 张星园(2002-),女,江西宜春人,本科,研究方向:智能模拟、人工智能和数值模拟。

通信作者: 李言(1990-),女,河北石家庄人,硕士,讲师,研究方向:数据挖掘理论及应用。

者也做了很多研究。李青会等^[3]采用外束质子激发X射线荧光（PIXE）、感应耦合等离子发射光谱（ICP-AES）等技术确定了中国古代玻璃的化学成分，从科技研究角度客观的探讨中国古代玻璃研究中存在的相关问题；董俊卿等^[4]利用外束PIXE和pXRF对河南出土东周至宋代玻璃器进行了无损分析，探索了不同时代化学成分体系。经研究发现，古代玻璃极易受埋藏环境的影响而风化。在风化过程中，内部元素与环境元素进行大量交换，导致其成分比例发生变化，从而影响对其类别的正确判断^[5]。因此表面风化也会对玻璃文物的分类造成影响。

基于对玻璃化学成分研究的基础，相关学者开始结合玻璃文物样品的化学成分和其他检测手段对

玻璃文物样品进行分类，目前，仅仅根据玻璃文物样品的化学成分比重和其是否表面风化两方面的影响因素，对玻璃文物样品的类型实现分类的方法尚未有相关研究。本文结合高钾玻璃和铅钡玻璃成分上的差异，提出基于CatBoost算法的玻璃文物样品分类模型，在玻璃文物样品科学分类中显示出特有的优势，为其考古研究提供更好的应用价值^[6]。

1 研究方案

1.1 数据准备

本文采用2022高教社杯全国大学生数学建模竞赛C题进行实验。对于尚未分类的玻璃文物样品，其化学成分和表面风化的基本信息见表1。

表1 待分类玻璃文物样品数据

文物编号		A1	A2	A3	A4	A5	A6	A7	A8
表面风化		无风化	风化	无风化	无风化	风化	风化	风化	无风化
化学成分/%	SiO ₂	78.45	37.75	31.95	35.47	64.29	93.17	90.83	51.12
	Na ₂ O	—	—	—	—	1.2	—	—	0
	K ₂ O	—	—	1.36	0.79	0.37	1.35	0.98	0.23
	CaO	6.08	7.63	7.19	2.89	1.64	0.64	1.12	0.89
	MgO	1.86	—	0.81	1.05	2.34	0.21	—	0
	Al ₂ O ₃	7.23	2.33	2.93	7.07	12.75	1.52	5.06	2.12
	Fe ₂ O ₃	2.15	—	7.06	6.45	0.81	0.27	0.24	0
	CuO	2.11	—	0.21	0.96	0.94	1.73	1.17	9.01
	PbO	—	34.3	39.58	24.28	12.23	—	—	21.24
	BaO	—	—	4.69	8.31	2.16	—	—	11.34
	P ₂ O ₅	1.06	14.27	2.68	8.45	0.19	0.21	0.13	1.46
	SrO	0.03	—	0.52	0.28	0.21	—	—	0.31
	SnO ₂	—	—	—	—	0.49	—	—	0
	SO ₂	0.51	—	—	—	—	—	0.11	2.26

1.2 数据预处理

1.2.1 缺失值处理

数据存在缺失的原因多种多样，其最终呈现出空缺的形式^[7,8]。在本文所使用的数据中，部分化学成分的比例未被检测到或者缺失，因此用

0进行填补。

1.2.2 异常值处理

对于玻璃文物样品的化学成分而言，其含量的特点是成分性，即各成分比例的累加和应为100%，但因检测手段等原因可能导致其成分比例的累加和

非100%的情况。一般将成分比例累加和为85%~105%视为正常值范围,在此范围外的数值会影响模型效果,即为异常值,需要进行删除处理。

1.3 研究方法

本文首先运用统计学中基于皮尔逊相关系数、肯德尔等级相关系数、斯皮尔曼相关系数的综合相关性分析研究不同玻璃类型的分类规律。为了便于分析玻璃类型和化学成分之间的关系,将玻璃类型转换为数值类型,即高钾玻璃设定为0,铅钡玻璃设为1。

1.3.1 皮尔逊相关性分析

本文首先使用皮尔逊相关性分析研究玻璃类型和14种化学成分之间的相关性。运用皮尔逊相关系数^[9]定义为该两个变量之间的协方差和标准差的商:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y} \quad (1)$$

估算样本的协方差和标准差,可以得到样本的相关系数,也就是样本皮尔逊系数:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (2)$$

上式中,也可由样本点的标准分数均值估计,得到等价表达式:

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma_X} \right) \left(\frac{Y_i - \bar{Y}}{\sigma_Y} \right) \quad (3)$$

其中 $(X_i - \bar{X})/\sigma_X$ 、 $\bar{X}$ 及 σ_X 分别是对样本 X_i 标准分数、样本平均值和样本标准差。

1.3.2 肯德尔相关性分析

肯德尔等级相关系数^[10]作为一种统计中常用来测量两个随机变量相关性的方法,基于 i, j 其中 $i < j$ 同序对的计算,可作用于本文根据化学成分研究玻璃文物样品分类规律。根据肯德尔计算公式:

$$\tau = \frac{N_c - N_d}{n \times (n-1)/2} \quad (4)$$

式中: N_c ——一致的个数;

N_d ——不一致的个数;

n ——元素的个数,本文中指被检测的玻璃文物样品中的化学成分个数,共14类。

1.3.3 斯皮尔曼相关性分析

由于各玻璃文物样品化学成分所占比例不同,可以使用斯皮尔曼相关系数法^[11,12]进行分析。它是根据两列成对等级的各对等级数之差来计算,且对于研究的两个变量对象,如果它们相关系数完全相同,则其斯皮尔曼相关系数可得+1或-1,也就是说,相关系数的绝对值越接近于1,两个变量之间的相关性越强^[13]。对于样本容量为 n 的样本, n 个原始数据被转换成等级数据,相关系数 ρ 为:

$$\rho = \frac{\sum_i (x_i - \bar{x})}{\sqrt{\sum_i (x_i - \bar{x}) \cdot \sum_i (y_i - \bar{y})}} \quad (5)$$

实际应用中,变量间的连结是无关紧要的,于是可以通过简单的步骤计算。被观测的两个变量的等级的差值,则 ρ 为:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (6)$$

1.3.4 CatBoost算法原理

为了建立精确的玻璃文物样品分类模型,本文选择了CatBoost算法进行建模。CatBoost算法^[14]是一种以对称决策树为基学习器实现的新型梯度提升算法,可有效减少数据的过度拟合,并使将待分类的数据参与训练^[15,16]。设定观测的数据集 $S = \{(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)\}$,其中, $X_i = (x_{i1}, x_{i2}, \dots, x_{im})$ 代表待分类数据中玻璃文物样品提供的14个化学成分与风化情况, Y_i 为标记值。

类别型特征是指类别是离散的特征,一般是字符串形式,每一种取值代表一种特定的类别,类别型特征不能直接用于算法输入中^[17],将转换为数值型的风化类型特征和待分类的数据集,生成多个随机序列,并用训练数据集平均标记值替代类别:

$$x_{jk} = \frac{\sum_{j=1}^n [x_{jk} = x_{ik}] \cdot Y_j}{\sum_{j=1}^n [x_{jk} = x_{ik}]} \quad (7)$$

设 $\theta = (\theta_1, \theta_2, \dots, \theta_n)$,将分类特征值转

化为数值，最终经过测试数据预测评估结果中对待分类文物概率的比较，可得到其文物类型的分类结果。

$$x_{\theta_{p,k}} = \frac{\sum_{j=1}^{p-1} [x_{\theta_{j,k}} = x_{\theta_{p,k}}] \cdot Y_{\theta_j} + a \cdot P}{\sum_{j=1}^{p-1} [x_{\theta_{j,k}} = x_{\theta_{p,k}}] + a} \quad (8)$$

2 结果分析

2.1 玻璃文物分类规律结果分析

通过综合相关性分析探究玻璃文物样品的分类规律，得到其皮尔逊相关性分析系数矩阵如图1所示。




图1 皮尔逊相关性分析矩阵

肯德尔等级相关系数如图2所示。




图2 肯德尔等级相关矩阵

斯皮尔曼相关系数如图3所示。




图3 斯皮尔曼相关系数矩阵

图1~图3是14种化学成分之间的综合相关性分析矩阵，其中颜色越深（相关系数的绝对值越大）代表两种化学成分之间的关联性越强^[18]，颜色越浅（相关系数的绝对值越小）代表两种化学成分之间的关联性越弱。并且，通常认为相关系数在0.8~1.0，说明两者之间存在极强相关，

0.6~0.8说明两者之间强相关，0.4~0.6说明两者相关程度中等，0.2~0.4说明两者之间的相关程度弱，0~0.2则证明两者之间仅存在极弱相关甚至无相关性。

根据高钾玻璃和铅钡玻璃的综合性评价分析结果，得到图4。




图4 两类玻璃与化学成分间的相关性分析统计

基于皮尔逊相关系数、肯德尔等级相关矩阵、斯皮尔曼相关系数矩阵对两类玻璃和其化学成分之间的相关性研究得到的相关性分析统计图，可以发现SiO₂、K₂O、PbO、BaO及SrO与玻璃

类型的相关性明显较显著，其他化学成分与玻璃类型无显著相关性，且根据对被检文物中上述五种化学成分占比的总结分析，被检测文物中PbO与玻璃类型具有强相关，SiO₂、K₂O、BaO及

SrO与玻璃类型的相关性为中等程度相关。其中铅钡玻璃氧化铅成分含量不低于10，高钾玻璃中不高于10；并且高钾玻璃中SiO₂和K₂O含量相对较高，铅钡玻璃中BaO和PbO含量相对较高。

2.2 玻璃文物样品分类结果分析

本研究通过调用python软件中CatBoost包进行

CatBoost分类建模。经过多次调试，最大树数（iterations）设置为100，树深（depth）设置为10，学习率（learning_rate）设置为0.1，其他值为默认值。在模型训练过程中，不同特征对分类结果的影响程度根据它们对模型贡献度而变化。各特征重要性占比如图5所示。




图5 特征重要性比例

由图5各特征的重要性^[19]中可以看出，对于分类结果而言，氧化铅对玻璃文物样品分类的贡献度最大，其次是氧化钡，而氧化锡和二氧化硫几乎对分类结果无贡献，因此可以认为玻璃文物样品的分类结果与这两个化学成分无关。从特征重要性结果可以得出，两类玻璃的分类规律具有合理性，从化学成分的偏好也可作为粗分类的方法。

模型训练完毕之后，得到A1~A8文物的分类结果如表2所示。

表2 A1~A8玻璃文物样品类型分类结果

文物编号	预测结果	文物编号	预测结果
A1	高钾	A5	铅钡
A2	铅钡	A6	高钾
A3	铅钡	A7	高钾
A4	铅钡	A8	铅钡

对待分类数据进行分类之后，为了评估所构建的模型的分类效果^[20]，本文计算了准确率、召回率和F1值，得到表3的评估结果。

表3 模型评估结果

准确率	召回率	F1
0.970	0.959	0.924

从表3可以得知，CatBoost分类模型在测试结果中，平均准确率为97%，平均召回率为95.9%，平均F1值为92.4%，说明误分类的概率很小，分类结果与实际结果误差不大，验证了本文所构建的分类模型具有可行性。

2.3 关联性和差异性结果分析

2.3.1 关联性分析

对高钾玻璃和铅钡玻璃文物样品依据公式（1）~（3）分别建立皮尔逊相关系数模型^[21]，

得到高钾玻璃和铅钡玻璃的皮尔逊相关系数分析 系数矩阵分别如图6和图7所示。




图6 高钾玻璃皮尔逊相关性分析系数矩阵

根据矩阵结果显示，在高钾玻璃中，CaO、MgO的相关性在0.4以上，且两者之间非常接近，说明在高钾玻璃中，CaO和MgO相关性在0.3以上，关联性较大；同样的，SiO₂、K₂O、CuO之间的关联性接近；而Na₂O、Al₂O₃、Fe₂O₃、PbO、BaO、SnO₂之间的关联性也较为接近。




图7 铅钡玻璃皮尔逊相关性分析系数矩阵

根据矩阵结果显示，在铅钡玻璃中，SiO₂、MgO、Al₂O₃、CuO之间的关联性相近；Na₂O、CaO、Fe₂O₃、P₂O₅和SnO₂之间的相关性相近。两类玻璃化学成分间存在关联性的同时，也存在着差异性。使用F检验^[22]对两类玻璃文物样品的化学成分进行差异性分析，得到表4。

2.3.2 差异性分析

表4 高钾玻璃和铅钡玻璃方差分析结果

变量名	变量值	平均值	标准差	F	P	变量名	变量值	平均值	标准差	F	P
SiO ₂	高钾	74.170	17.718	48.990	0.000***	CuO	高钾	2.227	1.483	0.390	0.535
	铅钡	39.068	18.795				铅钡	1.846	2.485		
Na ₂ O	高钾	0.439	1.063	1.171	0.283	PbO	高钾	2.514	9.773	67.239	0.000***
	铅钡	0.923	1.827				铅钡	33.152	15.041		
K ₂ O	高钾	6.065	5.363	58.827	0.000***	BaO	高钾	0.659	1.400	26.163	0.000***
	铅钡	0.177	0.277				铅钡	10.598	8.385		
CaO	高钾	3.797	3.222	8.771	0.004***	P ₂ O ₅	高钾	1.439	2.180	3.394	0.070*
	铅钡	2.032	1.647				铅钡	3.177	3.865		
MgO	高钾	0.775	0.693	0.524	0.472	SrO	高钾	0.036	0.057	26.079	0.000***
	铅钡	0.647	0.637				铅钡	0.351	0.265		
Al ₂ O ₃	高钾	4.978	3.009	2.536	0.116	SnO ₂	高钾	0.124	0.541	0.499	0.482
	铅钡	3.670	3.041				铅钡	0.059	0.215		
Fe ₂ O ₃	高钾	1.374	1.522	5.614	0.021**	SO ₂	高钾	0.064	0.154	1.059	0.307
	铅钡	0.642	0.953				铅钡	0.816	3.170		

注：***、**、*分别代表1%、5%、10%的显著性水平

从表4可以看出，不同的玻璃文物样品类型在SiO₂、K₂O、CaO、Fe₂O₃、PbO、BaO和SrO含量上存在显著差异，而在Na₂O、MgO、Al₂O₃、CuO、P₂O₅、SnO₂和SO₂含量上不存在显著差异。

3 结论

本文提出了一种基于CatBoost算法对玻璃文物样品的分类方法，可对已知玻璃文物样品表面是否风化和其所含化学成分比例对未知玻璃文物进行高钾和铅钡类型分类。分析了不同化学成分之间的关联性以及高钾玻璃和铅钡玻璃的分类规律，构建了以15个特征作为输入向量，建立了基于CatBoost算法的玻璃文物样品分类模型，并验证了分类模型的有效性。得出以下结论：

（1）统计高钾玻璃和铅钡玻璃文物样品的分类规律，可得两类玻璃的化学成分含量有偏重：高钾玻璃中氧化硅和氧化钾含量相对较高，铅钡玻璃中氧化钡和氧化铅含量相对较高。

（2）训练玻璃文物分类模型过程时，氧化铅、氧化钡、二氧化硅和氧化钾的特征重要性程度分别为41.40%、12%、8.8%和3.5%，说明这四种化学成分对于分类结果而言，贡献度很大，验证了高钾玻璃和铅钡玻璃分类规律的正确性。

（3）考古工作者依据古代玻璃制品的化学成分和其他检测手段将其分为高钾玻璃和铅钡玻璃两种类型，通过CatBoost算法对玻璃文物样品进行分类模型的平均准确率达到97%，平均召回率为95.9%，平均F1值为92.4%，说明分类结果和实际结果的误差很小，因此该算法对考古科研工作者分类未知玻璃文物样品具有重要意义。

参考文献

[1] Do Khai Ly, 苏森, 杨媛媛. 传播与共融——中国文化对丝绸之路沿线装饰艺术的影响[J]. 东华大学学报(社会科学版), 2022, 22 (02) : 37-46.

[2] 成倩, 郭金龙, 王博, 等. LA-ICP-AES 分析丝绸之路出土玻璃器成分特点[J]. 光谱学与光谱分析, 2012, 32

- (07):1955-1960.
- [3] 李青会, 干福熹, 顾冬红. 关于中国古代玻璃研究的几个问题[J]. 自然科学史研究, 2007, (02): 234-247.
- [4] 董俊卿, 李青会, 干福熹, 等. 一批河南出土东周至宋代玻璃器的无损分析[J]. 中国材料进展, 2012, 31 (11): 9-15.
- [5] 李清临, 徐承泰, 凌雪, 等. 一批金元时期古玻璃的EDXRF探针无损分析[J]. 光谱学与光谱分析, 2011, 31 (07): 1960-1963.
- [6] 付强, 赵虹霞, 董俊卿, 等. 河南宝丰和新郑出土硅酸盐制品的无损分析研究[J]. 光谱学与光谱分析, 2014, 34 (01): 257-262.
- [7] 杜英魁, 张乙芳, 原忠虎, 等. 数据预处理对LSTM网络大气污染预测精度分析[J]. 计算机与数字工程, 2021, 49 (7): 1400-1404+1425.
- [8] 蒋奇峰, 杜景林, 周芸. 一种基于QPSO-RBF模型预测PM_{2.5}浓度值的方法研究及应用[J]. 计算机应用与软件, 2020, 37 (9): 202-208.
- [9] 王照国, 张红云, 苗夺谦. 基于F1值的非极大值抑制阈值自动选取方法[J]. 智能系统学报, 2020, 15 (05): 1006-1012.
- [10] Van Doorn J, Ly A, Marsman M, et al. Bayesian inference for Kendall's rank correlation coefficient[J]. The American Statistician, 2018, 72 (4): 303-308.
- [11] 贾科, 杨哲, 魏超, 等. 基于斯皮尔曼等级相关系数的新能源送出线路纵联保护[J]. 电力系统自动化, 2020, 44 (15): 103-111.
- [12] 贾晓芬, 郭永存, 黄友锐, 等. 基于斯皮尔曼等级相关性的彩色图像椒盐噪点检测算法[J]. 中国科学技术大学学报, 2019, 49 (01): 63-70.
- [13] 梁吉业, 冯晨娇, 宋鹏. 大数据相关分析综述[J]. 计算机学报, 2016, 39 (1): 1-18.
- [14] Dorogush A V, Ershov V, Gulin A. CatBoost: gradient boosting with categorical features support[J]. arXiv preprint arXiv: 1810.11363, 2018.
- [15] 陈点点, 陈芸芝, 冯险峰, 等. 基于超参数优化CatBoost算法的河流悬浮物浓度遥感反演[J]. 地球信息科学学报, 2022, 24 (04): 780-791.
- [16] 卢汉, 郭大立, 李曙光, 等. 基于CatBoost-Adam结合的煤层气产量通用预测与优化方法研究[J]. 科技通报, 2021, 37 (07): 1-6+12.
- [17] 党存禄, 杨海兰, 武文成. 基于LSTM和CatBoost组合模型的短期负荷预测[J]. 电气工程学报, 2021, 16 (03): 62-69.
- [18] 阮少军, 费逸伟, 马军, 等. 烃类航空润滑油高温氧化产物的理化指标关联性分析[J]. 润滑与密封, 2018, 43 (7): 111-115.
- [19] 徐少成, 李东喜. 基于随机森林的加权特征选择算法[J]. 统计与决策, 2018, 34 (18): 25-28.
- [20] 李倩玉, 王蓓, 金晶, 等. 基于双向LSTM卷积网络与注意力机制的自动睡眠分期模型[J]. 智能系统学报, 2022, 17 (03): 523-530.
- [21] Obilor E I, Amadi E C. Test for significance of Pearson's correlation coefficient[J]. International Journal of Innovative Mathematics, Statistics & Energy Policies, 2018, 6 (1): 11-23.
- [22] 郭鸿飞. F检验法和T检验法在方法验证过程中的应用探究[J]. 山西冶金, 2019, 42 (04): 114-116.