

DOI:10.15923/j.cnki.cn22-1382/t.2025.6.09

基于随机森林及 K-means++ 对玻璃文物的成分分析与鉴别

刘振文¹, 何彭^{2*}

(1. 吉林建筑科技学院 基础部, 吉林 长春 130114;

2. 电子科技大学 计算机科学与工程学院, 四川 成都 611731)

摘 要: 实验主要以是否风化的高钾、铅钡硅酸盐玻璃为研究对象, 针对风化前后玻璃纹饰、类型以及颜色的关系, 使用 Kendall tau 系数及其 P 值探究之间的相关性和差异性, 其中, 纹饰和类型与风化系数分别为 $-0.003\ 6$ 和 -0.344 , 颜色与风化系数为 0.121 。对于分类模型, 建立随机森林(Random Forest, RF)及 K-means++ 算法, 使用网格寻优对 RF 超参数进行调节, 以此来获得影响样本分类的 7 个重要指标进行数据降维, 对降维的数据使用 K-means++ 算法, 结合“肘”部图对类别进行选择, 实验以铅钡玻璃为例, 得出其可分为 5 个类。对于预测模型建立基于梯度下降的多因素 Logistic 回归模型, 使用梯度下降思想, 对 Logistic 回归模型的 β 参数进行迭代寻找, 模型的准确率和 ROC 曲线均为 1。利用 LIME 模型, 扰动 $1\% \sim 10\%$ 的数据, 发现预测模型合理且稳定。为后续研究古代硅酸盐玻璃是否风化、分类和预测提供一定的参考价值。

关键词: 硅酸盐玻璃; 随机森林; K-means++; 梯度下降; Logistic 回归; LIME

中图分类号: O 29 **文献标志码:** A **文章编号:** 1674-1374(2025)06-0545-07

Compositional analysis and identification of glass artifacts based on random forest and K-means++

LIU Zhenwen¹, HE Peng^{2*}

(1. Basic Science Department, Jilin University of Architecture and Technology, Changchun 130114, China;

2. Computer Science and Technology, University of Electronic Science and Technology of China, Chengdu 611731, China)

Abstract: In this paper, the Kendall tau coefficient and its P value were used to explore the correlation and difference between the glass ornamentation, type and color before and after weathering, in which the ornamentation, type and weathering coefficient were $-0.003\ 6$ and -0.344 , and the color and weathering coefficient were 0.121 . For the classification model, the Random Forest (RF) and

收稿日期: 2025-08-27

基金项目: 教育部产学合作协同育人项目(20250104122611)

作者简介: 刘振文(1978—), 男, 汉族, 吉林长春人, 吉林建筑科技学院副教授, 博士, 主要从事随机微分方程方向研究, E-mail: 912322692@qq.com. * 通信作者: 何彭(2002—), 男, 汉族, 四川宜宾人, 电子科技大学硕士研究生, 主要从事深度学习、机器学习方向研究, E-mail: 2782585904@qq.com.

K-means++ algorithm are established, and the RF hyperparameters are adjusted by grid optimization, so as to obtain 7 important indicators affecting the classification of the sample, the data dimensionality is reduced, the K-means++ algorithm is used for the dimensionality reduction data, and the categories are selected in combination with the "elbow" part diagram, and the experiment takes lead barium glass as an example, and it is concluded that it can be divided into 5 categories. For the prediction model, a multivariate logistic regression model based on gradient descent is established, and the parameters of the logistic regression model are iteratively searched for by using the gradient descent idea, and the accuracy and ROC curve of the model are 1. Using the LIME model, 1%~10% of the data are disturbed, and the prediction model is found to be reasonable and stable. It provides certain reference value for subsequent research on whether ancient silicate glass is weathered, classified and predicted.

Key words: portland glass; Random Forest (RF); K-means++; gradient descent; Logistic regression; LIME.

0 引言

玻璃是早期贸易往来的宝贵物证。早期的玻璃在西亚和埃及地区常被制作成珠形饰品传入我国,促进了中国古代玻璃产业发展^[1],我国古代的玻璃由于在埋藏过程中容易受到环境变化的影响,容易风化,导致玻璃的成分比例发生变化,影响对其所属类别的判断。文中希望通过研究古代玻璃的风化、分类和预测等问题为鉴别风化玻璃方法做一个先行性的铺垫。

首先是风化与稳定问题,被埋藏的古玻璃因埋藏的地理位置等因素比较容易受到风化。王承遇等^[2]、陶瑛等^[3]对风化环境、风化机理进行深入研究;周艳艳等^[4]使用粉末法对 ZF_7 铅玻璃稳定性进行测定。其次是分类问题,在传统玻璃分类方法中;张智恒等^[5]使用灰色聚类进行玻璃品种鉴别;张帅凡等^[6]使用 Fisher 线性判别分析进行分类;李青会等^[7]对古代玻璃的重要化学成分进行了鉴别与分析。但是单纯通过化学研究手段还不能够较为准确地进行分类。近些年来,机器学习^[8]被广泛应用于材料领域的探究,路佳佳^[9]使用集成特征选择和随机森林(Random Forest, RF)对玻璃进行分类研究;郝强^[10]使用深度学习方法对玻璃进行缺陷分类。最后是预测问题,王祉皓等^[11]基于机器学习实现风化玻璃原成分预测;张会刚等^[12]通过将多个性质加权平均转化为一个综合指数来划分。通过查阅文献可知,国内外在使用机器学习对古代硅酸盐玻璃的风化、分类以及预测问题进行研究方面尚且存在空白。

文中使用 Kendall tau 系数^[13]对风化前后的

玻璃类型、纹饰、颜色的关系进行相关性分析。使用决策树^[8,14]对高钾玻璃和铅钡玻璃进行预分类分析,进一步则使用基于 RF^[8,15]及 K-means++ 聚类算法^[16]进行类划分,其中利用网格寻优^[17]的 RF 模型对指标进行降维处理,从而提取有效数据进行 K-means++ 聚类分析。建立基于梯度下降^[18]的多因素 Logistic 回归模型^[19],实现预测采用梯度下降算法调整参数 β ,从而得出鉴别结果。针对敏感性分析,文中使用可解释性机器学习中 LIME 模型思想^[20-21]对数据进行扰动处理,探究所建模型的灵敏度值,从而得出模型的可利用价值。

1 方法

1.1 RF

1.1.1 决策树与集成学习

决策树^[8,14]是用来解决分类与回归问题的一种监督学习算法,是一种预测模型,代表对象属性和对象值之间的一种映射关系。集成学习^[8]通过构造多个机器学习器来解决分类问题、回归问题和特征提取等多类问题,RF 则是由多棵随机生成的决策树集成而来。集成过程如图 1 所示。




图 1 集成学习过程

1.1.2 Bagging 与获得指标重要性

Bagging^[8,22]采用自助采样过程,优点是对于每个基学习器只使用了初始训练集中约 63.2% 的样本,剩下约 36.8% 的样本可用作验证集来对泛化性能进行“包外估计”(OOB)^[8]。

设 D_i 表示 h_i 实际使用的训练样本集,设 $H^{\text{OOB}}(x)$ 表示对样本 x 的 OOB,即仅考虑那些未使用 x 训练的基学习器在 x 上的预测,数学公式解释为

$$H^{\text{OOB}}(x) = \operatorname{argmax}_{y \in Y} \sum_{t=1}^T \|(h_t(x) = y) \cdot \mathbb{I}(x \notin D_t)\|. \quad (1)$$

指标重要性计算如下^[23]:

1) 先用 OOB 数据测试已生成的 RF 性能,得到一个 OOB 准确率;

2) 然后在 OOB 数据中人为地给某特征变量 v 加入噪声值,再用加入噪声后的 OOB 数据测试 RF 的性能,得到一个新的 OOB 准确率(或基尼值);

3) 原始 OOB 准确率(基尼值)与加入噪声后的 OOB 准确率(基尼值)之差,作为相应特征变量 v 的重要性度量值。

1.2 K-means++

K-means++ 聚类算法^[8,16]是一种基于已知的基类目标函数,采用一种更新迭代的方法,每一次迭代都在向目标函数减小的目标靠近,最终聚类结果使目标函数取得极小值,达到较好的分类效果。K-means++ 聚类算法流程如图 2 所示。

1.3 逻辑回归(Logistic)

在给定 x 的情况下,Logistic^[19]是由两点分布(伯努利分布)推导出来的,考虑 y 的两点分布概率,解释为

$$\begin{cases} P(y=1|x) = F(x, \beta), \\ P(y=0|x) = 1 - F(x, \beta), \end{cases} \quad (2)$$

式中: $F(x, \beta)$ ——连接函数,是定义在 $[0, 1]$ 上的函数,进而保证 $0 \leq y \leq 1$;

y ——事件发生的概率, $y=1$ 。

$F(x, \beta)$ 可以取为 Sigmoid 函数,表示为

$$F(x, \beta) = S(x'_i \beta) = \frac{\exp(x'_i \beta)}{1 + \exp(x'_i \beta)}. \quad (3)$$




图2 K-means++聚类算法流程

2 模型建立

2.1 数据获取和预处理

文中数据来源于“古代玻璃制品的成分分析与鉴别”^[24]。由于原数据检测手段等其他原因,存在部分数据成分缺失,或者检测错误,文中对缺失的数据使用 0 值填补,玻璃成分比例累加小于 85%,或大于 105% 的数据视为无效数据(累加成分比例 85%~105% 视为准确测量数据),无效数据予以剔除^[25],并进一步对玻璃各属性的相关性进行分析。

2.2 风化玻璃分类模型

建立基于 RF 及 K-means++ 分类模型进行风化玻璃分类处理。利用网格寻优后的 RF 模型对样本数据进行降维,找到影响两种玻璃分类的重要化学成分,再用 K-means++ 算法进行聚类,结合“肘”部图^[26]找到最优聚类数,给出划分结果。

分类模型流程如图 3 所示。




图 3 基于 RF 及 K-means++ 算法的分类模型流程

2.3 风化玻璃预测模型

建立基于梯度下降的多因素 Logistic 预测模型,用于风化玻璃的预测。利用梯度下降解决带 Logistic 目标参数的最优问题,通过不断迭代,随后使用极大似然估计法获得目标参数,最终判断未知文物所属类型。实验中使用 Sigmoid 函数,利用极大似然估计法(简称为 MLE)进行估计,解释为

$$\ln L(\beta | y, x) = \sum_{i=1}^n y_i \ln[S(x_i \beta)] + \sum_{i=1}^n (1 - y_i) \ln[1 - S(x_i \beta)]. \quad (4)$$

利用梯度下降法对参数 β 进行估计为

$$\beta = \beta_j - \frac{\alpha}{m} \frac{\partial(-\ln(\beta))}{\partial \beta} = \beta_j - \frac{\alpha}{m} \sum_{i=1}^m x_i (h(\beta^T x_i) - y_i), \quad (5)$$

式中: α ——学习率。

利用 $\hat{y}_i$ 预测公式为

$$\hat{y}_i = P(y_i = 1 | x) = S(x_i', \hat{\beta}) = \frac{\exp(x_i' \hat{\beta})}{1 + \exp(x_i' \hat{\beta})}$$

$$\frac{e^{\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \dots + \hat{\beta}_k x_{ki}}} \quad (6)$$

最后利用 $\hat{y}_i$ 来鉴定未知文物所属类型。

3 结果与分析

3.1 分化前后的玻璃各属性之间相关性分析

文中使用 Python、SPSS、Matlab 等统计工具,结合 Kendall tau 系数及其 P 值对风化玻璃前后类型、纹饰以及颜色的相关性和差异性进行对比分析,分别见表 1 和表 2。

表1 Kendall tau相关系数矩阵

	纹饰	类型	颜色	表面风化
纹饰	1	0.115	0.379	-0.036
类型	0.115	1	0.405	-0.344
颜色	0.379	0.405	1	0.121
表面风化	-0.036	-0.344	0.121	1

表2 Kendall tau方法的P值

P 值			
1	0.3739	0.0011	0.7852
0.3739	1	0.0008	0.0096
0.0011	0.0008	1	0.3166
0.7852	0.0096	0.3166	1

对表 1 和表 2 分析可知,纹饰和类型与表面风化呈现负相关,系数分别为 -0.0036 和 -0.344 ,颜色与表面风化呈现正相关,系数为 0.121 。玻璃类型对表面风化影响最大(相关系数绝对值最大),其次是颜色、纹饰。

3.2 基于 RF 及 K-means++分类

利用网格寻优后的 RF 处理相关数据,获得指标重要性后进行数据降维,选出氧化铅、氧化钡、二氧化硅、氧化锶、氧化钾、氧化铝和五氧化二磷 7 个化学物质作为重要特征见表 3。

利用 K-means++聚类方法对玻璃文物进行分类划分,使用 SPSS 软件对铅钡玻璃的数据分别进行 4 类、5 类和 6 类三种划分,并给出离中心

点距离。

表 3 降维后得到的 7 个重要指标

化学物质	重要程度
氧化铅(PbO)	0.282 425 389
氧化钡(BaO)	0.221 199 288
二氧化硅(SiO ₂)	0.155 704 216
氧化锶(SrO)	0.115 751 390
氧化钾(K ₂ O)	0.094 721 498
氧化铝(Al ₂ O ₃)	0.079 661 209
五氧化二磷(P ₂ O ₅)	0.050 537 009

铅钡玻璃的 K-means++聚类结果见表 4。

表 4 铅钡玻璃的 K-means++聚类结果

分类情况	4 类		5 类		6 类	
	类别/个	离中心点距离	类别/个	离中心点距离	类别/个	离中心点距离
1	6	9.37	6	9.36	9	6.50
2	20	11.00	12	10.10	6	9.36
3	4	8.44	5	10.00	4	8.40
4	19	11.02	16	9.34	16	9.00
5	/	/	10	6.90	11	7.70
6	/	/	/	/	3	10.90

利用 SPSS 软件计算出铅钡玻璃的聚合系数,并画出折线图,如图 4 所示。




图 4 铅钡玻璃的聚合系数曲线(“肘”部图)

由图 4 分析可知:
1)当类别数为 5 时,折线的下降趋势趋缓。
2)K 值从 1 到 5 时,曲线尤为陡峭。超过 5 以后,曲线趋于平缓。最终铅钡玻璃聚类结果 5 个类别是比较合理的。

3.3 基于梯度下降的多因素 Logistic 预测

利用极大似然法,实验中设置参数学习率为 0.001 ,迭代 $1\ 500$ 次后停止,最后得出包含常数

项在内的 8 个系数($\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6, \beta_7$),利用模型重新计算分类分数 $\hat{y}_i$ (见式(6)),得到表达式为

$$\hat{y}_i = \frac{e^{-0.004\ 3+0.08\text{SiO}_2-0.21\text{K}_2\text{O}-0.082\text{Al}_2\text{O}_3-0.63\text{PbO}-0.19\text{BaO}+0.004\text{P}_2\text{O}_5-0.007\text{SrO}}}{1+e^{-0.004\ 3+0.08\text{SiO}_2-0.21\text{K}_2\text{O}-0.082\text{Al}_2\text{O}_3-0.63\text{PbO}-0.19\text{BaO}+0.004\text{P}_2\text{O}_5-0.007\text{SrO}}}$$

最后对未知类别的玻璃文物进行鉴别,结果见表 5。

表 5 基于梯度下降的多因素 Logistic 预测结果

文物编号	鉴别结果
A1	1
A2	0
A3	0
A4	0
A5	0
A6	1
A7	1
A8	0

表中:1 为高钾玻璃,0 为铅钡玻璃。

实验中,该模型在训练集上的准确率为 100%,见表 6。

表 6 基于梯度下降的多因素 Logistic 回归模型分类准确率 %

指标	铅钡样本数	高钾样本数
预测前	49	20
预测后	49	20
成功率	100	100

ROC 曲线如图 5 所示。




图 5 ROC 曲线

3.4 模型的合理性和敏感性分析

在前述基础上,利用 LIME 模型思想对未知文物的化学成分进行 1%、2%、5%、7%、10% 扰动处理,判断文物 A1~A8 预测情况,对预测模型进行敏感性分析,扰动后预测结果见表 7。

表 7 LIME 扰动数据后玻璃文物的稳定性预测结果

文物编号	1%	2%	5%	7%	10%
A1	稳定	稳定	稳定	稳定	稳定
A2	稳定	稳定	稳定	稳定	稳定
A3	稳定	稳定	稳定	稳定	稳定
A4	稳定	稳定	稳定	稳定	稳定
A5	稳定	稳定	稳定	稳定	稳定
A6	稳定	稳定	稳定	稳定	稳定
A7	稳定	稳定	稳定	稳定	稳定
A8	稳定	稳定	稳定	稳定	稳定

由表 7 可知,使用 LIME 数据扰动思想,发现预测情况不变(稳定),说明模型敏感性低,稳定性好,模型具有良好的鲁棒性。

4 结 语

使用 Python、SPSS、MATLAB 等统计工具对收集的古代玻璃是否风化的数据进行预处理,使用 Kendall tau 系数以及它的 P 值对分化前后的玻璃类型、是否风化、纹饰以及颜色的关系进行初探究,对于玻璃的分类模型,使用基于 RF 及 K-means++ 算法实现分类,使用网格寻优的思想对 RF 参数进行调节,随后获得样本数据的指标重要性进行数据降维,之后使用 K-means++ 对样本进行聚类分析,给出不同类别的中心距离,并结合“肘”部图对聚类中心进行选择,该方法具有一定参考价值。考虑到最终聚类结果分散性与多样性,针对预处理部分可以考虑对数据进行扩充、补充,进而获得更多的有效数据,针对 RF 模型参数可以设置更大的迭代轮数,对更多的参数进行调节,找到适合本问题的最佳模型,实现更加精确的数据降维,对聚类数据优化,届时结合实验,进一步挖掘数据相关性,对玻璃分类进行更加准确的定义,更加有效地提高材料的使用效率以及实验的可靠性。

对于分类预测,文中建立基于梯度下降的多因素 Logistic 回归模型,使用机器学习的梯度下降思想,对 Logistic 回归模型的 β 参数进行迭代,进行分类预测,该模型在测试集的准确率以及 ROC 曲线都表现优秀,为了探究所建模型的合理和准确性,使用 LIME 局部可解释性思想,对样本数据进行 1%~10% 的扰动处理,最后给出扰动结果以及模型的合理性和灵敏度分析。通过使用改进模型进行预测,使得结果更具有可靠性和准确性。针对 β 参数的优化,可以寻找更多轮数的参数结果,并且对数据进行扩充,进一步探究所建模型的准确性,由于使用 LIME 模型时对样本数据进行扰动只是停留在样本层面,且范围只有 1%~10%,虽然实验结果较为理想,但并不能确定进行更大的扰动后模型的预测准确度情况,由于目前的机器学习模型大多数都为黑盒模型,很难解释真正的模型内部变化,进行更加直观的展示,因此在模型选择或者模型数据扰动时,应该投入更多的研究,以支撑模型结论,将所建立的模型切实地运用到实际生产生活中。

参考文献:

[1] 黄小娇. 中国国家博物馆藏中西方古代玻璃器比较

- 研究[J]. 文物天地, 2023, 381(3): 86-91.
- [2] 王承遇, 陶瑛. 硅酸盐玻璃的风化[J]. 硅酸盐学报, 2003(1): 78-85.
- [3] 陶瑛, 薄学微, 王承遇. 钡磷酸盐光学玻璃风化的研究[J]. 硅酸盐学报, 1996(4): 53-57.
- [4] 周艳艳, 王新伟, 裴春燕. 影响光学玻璃化学稳定性测定结果的因素分析[J]. 长春理工大学学报(自然科学版), 2007(1): 95-97.
- [5] 张智恒, 夏一凡, 舒文豪, 等. 古代玻璃制品的成分分析与种类鉴别[J]. 中国科技期刊数据库工业(A), 2023(1): 4-8.
- [6] 张帅凡, 孙瑞娟, 任涵卓. 古代玻璃制品的化学成分分析与相关性研究[J]. 化工管理, 2023(8): 41-44.
- [7] 李青会, 周虹志, 贵教珍, 等. 一批中国古代玻璃珠化学成分的检测报告[J]. 江汉考古, 2005, 4: 81-88.
- [8] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016: 33-37.
- [9] 路佳佳. 基于集成特征选择和随机森林的古代玻璃分类模型[J]. 硅酸盐学报, 2023, 51(4): 1060-1065.
- [10] 郝强. 基于深度学习的手机玻璃盖板缺陷检测研究[D]. 广州: 华南理工大学, 2021.
- [11] 王祉皓, 赵芾, 李智群, 等. 基于机器学习的风化硅酸盐玻璃原成分预测及亚分类方法[J]. 硅酸盐学报, 2023, 51(2): 416-426.
- [12] 张会刚, 朱庆山. 遗传算法 GA 结合 BFGS 预测玻璃组成[J]. 计算机与应用化学, 2003, 20(3): 5-8.
- [13] 赵美言, 胡涛, 张玉虎, 等. 基于机器学习模型的海河北系干旱预测研究[J]. 干旱区地理, 2020, 43(4): 9-11.
- [14] 张小云, 康晓霞. 基于决策树算法的网络入侵检测系统设计与评估[J]. 信息技术, 2023, 47(2): 117-122.
- [15] 张炳华, 张德锂, 谷昌军, 等. 基于随机森林与特征选择的藏东南土地覆被分类方法及精度评价[J]. 地理科学, 2023, 3: 1-10.
- [16] 方诗乔, 胡佩玲, 黄莹莹, 等. K-means 算法的优化及应用[J]. 现代信息科技, 2023, 7(6): 111-115.
- [17] 张蓓蓓, 胡敏. 基于网格搜索改进随机森林的顾客满意度预测[J]. 北京信息科技大学学报(自然科学版), 2021(4): 25-30.
- [18] 王昕. 梯度下降及优化算法研究综述[J]. 电脑知识与技术: 学术交流, 2022(8): 71-73.
- [19] 李桂琴, 邹若飞. 肺磨玻璃结节胸部 CT 影像特征及恶性 Logistic 多因素预测模型构建研究[J]. 影像研究与医学应用, 2022, 6(18): 59-61.
- [20] 林志萍, 杨立洪. 基于 LIME 的改进机器学习可解释性方法[J]. 数据挖掘, 2021, 11(2): 12-15.
- [21] 黄艺龙, 秦小林, 陈芋文, 等. 利用 LIME 对脓毒症预测模型进行可解释性分析[J]. 计算机应用, 2021, 41(S1): 332-335.
- [22] 曹杰, 邵笑笑. 基于信息增益和 Bagging 集成学习算法的个人信用评估模型研究[J]. 数学的实践与认识, 2016, 46(8): 90-98.
- [23] 路菡. 基于违约状态显著判别的批发零售小企业信用评价研究[D]. 咸阳: 西北农林科技大学, 2022.
- [24] 王丽, 王涛. 极端梯度提升改进的森林优化特征选择算法[J]. 长春工业大学学报, 2024, 45(4): 377-384.
- [25] 张丽艳, 李洪, 陈树彬, 等. 玻璃的成分和性质的模拟方法[J]. 硅酸盐学报, 2022, 50(8): 2338-2350.
- [26] 孙林, 刘梦含, 徐久成. 基于优化初始聚类中心和轮廓系数的 K-means 聚类算法[J]. 模糊系统与数学, 2022, 36(1): 47-65.