

多元数学建模分析古风化玻璃成分研究

熊 强¹, 张瀚文², 张宏俊², 方琦莹², 叶 昊³

(1. 南京邮电大学 通信与信息工程学院, 江苏 南京 210003; 2. 南京邮电大学 物联网学院, 江苏 南京 210003;
3. 南京邮电大学 国家邮政局邮政行业技术研发中心[物联网技术], 江苏 南京 210003)

[摘 要] 针对不同风化情况的高钾玻璃和铅钡玻璃样品, 运用相关性分析、多元线性回归、聚类分析等多种数学建模方法, 研究风化过程中化学成分变化规律. 通过多方法交叉验证, 包括斯皮尔曼相关分析、Wilcoxon 符号秩检验、Fisher 判别分析等, 确保分析结果的稳健性. 结果表明, 高钾玻璃在风化过程中二氧化硅含量增加, 氧化钾与氧化铝含量下降; 铅钡玻璃中氧化铅和氧化钡含量上升, 二氧化硅含量下降. 研究结果为古代玻璃文物的鉴别与保护提供了参考依据, 建立的模型具有良好的预测精度和鲁棒性.

[关键词] 相关性分析; 决策树; K-means 聚类分析; 典型相关分析; 多方法交叉验证

[中图分类号] TP391.9 **[文献标识码]** A **[文章编号]** 1009-2102(2025)04-0007-16

DOI:10.14084/j.cnki.cn62-1188/n.2025.04.009

0 引言

古代玻璃制品通过化学成分分析能够识别其类型与制作工艺. 中国古代玻璃主要分为高钾玻璃和铅钡玻璃, 两者在化学成分和风化特征上存在显著差异. 研究这些玻璃制品的风化过程及其成分变化, 对于鉴别文物来源、揭示历史贸易路线及保护文化遗产具有重要意义.

本研究整合多种统计分析方法(包括 Spearman 相关系数、Wilcoxon 符号秩检验、决策树和 K 均值聚类), 不仅揭示了不同类型玻璃风化机制的差异, 还通过多元数学建模建立了精准、稳健的预测模型. 基于较大样本量(58 件玻璃文物), 在样本多样性和数据可靠性方面优于以往研究, 这为模型的普适性和预测精度提供了坚实基础. 引入典型相关分析, 深入探讨高钾玻璃与铅钡玻璃在化学成分上的关联性与差异性, 补充了现有研究中关于成分的关联性.

1 概念与研究情况

1.1 古代玻璃制品及其分类

古代玻璃制品根据其主要成分的不同, 分为高钾玻璃和铅钡玻璃.

[收稿日期] 2024-11-26

[基金项目] 国家自然科学基金项目(61672296); 南京邮电大学大学生创新训练计划项目(XYB2019331)

[通信作者] 张宏俊, 男, 高级工程师, 博士, 主要从事高性能计算、大数据关键技术方面的研究.

[作者简介] 熊强, 男, 硕士研究生, 主要研究方向为信道编码、数据预测、资源分配.

高钾玻璃富含氧化钾(K_2O),这类玻璃在风化过程中表现出二氧化硅(SiO_2)含量增加,氧化钾和氧化铝(Al_2O_3)含量下降的特征.铅钡玻璃以氧化铅(PbO)和氧化钡(BaO)含量高为特征.在风化过程中,氧化铅和氧化钡含量上升,二氧化硅含量下降^[1-2].但现有分类方法主要基于主要氧化物含量的定性分析,缺乏多元统计模型的定量分类机制.本研究通过多元数学建模和数据分析,不仅确认了传统分类方法的有效性,还进一步揭示了微量元素在不同风化程度下的变化规律,为玻璃制品的更精细分类提供了新的视角.

1.2 古代玻璃风化及其成分研究进展

玻璃风化是影响古代玻璃文物保存状态的关键因素,受到多种环境与材料因素的影响.而多元统计分析方法已广泛应用于玻璃风化过程中的成分变化,揭示不同类型玻璃变化规律,为文物鉴定与保护提供了科学依据.现有研究在样本量、数据处理和模型验证方面仍存在不足,需进一步优化^[3].

1.3 模型假设与符号说明

为确保研究的合理性,本研究基于以下假设:未风化点能准确反映玻璃的原始成分;化学成分间存在线性相关性,适用于多元回归分析;玻璃亚类的划分以化学成分的相似性为依据,通过聚类分析实现精细分类.文中使用的符号和解释: R_s (斯皮尔曼相关系数); WT (风化物质含量); GT (一般物质含量); WG (风化程度虚拟变量); K (风化比例系数); t (三种风化程度); t_1 (未风化情况); t_2 (正常风化情况); t_3 (严重分化情况); Wt (风化程度下样本化合物加权平均值).


2 多元数学建模与成分分析

本文基于58件玻璃文物,探讨玻璃表面风化与类型、颜色、纹饰及化学成分的关系.通过Spearman相关系数^[4]、Wilcoxon符号秩检验、决策树、K均值聚类等方法,揭示了不同类型玻璃的风化机制差异,建立了预测模型.

2.1 玻璃文物表面风化特征分析

2.1.1 表面风化与类型、颜色、纹饰的关系

根据文献研究^[5-6],重点考察表面分化与类型、颜色、纹饰因素间的相关性.首先,使用Excel绘制折线图(图1、图2、图3)直观展示各因子与风化情况的关系.



为更精确地量化各因子与风化情况的相关性,采用Spearman秩相关系数来分析.Spearman秩相关系数是一种非参数指标^[7],适用于等级数据和顺序数据.定义 X 和 Y 为两组数据,计算公式:

$$R_s = 1 - \frac{6 \sum_{i=1}^n (X_i - Y_i)^2}{n(n^2 - 1)}.$$

$R_s = 1$ 时,称 X, Y 完全相关,此时 X, Y 之间具有线性函数关系; $R_s > 0.8$ 时称为高度相关, $R_s < 0.3$ 时称为低度相关,其他时候为中度相关.

由于样本数量为 $58 > 30$,样本数量较大,采用假设检验公式:

$$R_s \sqrt{n-1} \sim N(0, 1); H_0: R_s = 0, H_1: R_s \neq 1$$

计算 $R_s \sqrt{n-1}$,并求出对应的 P 值.

通过SPSS软件计算得到相关系数(见表1).结果显示,文物风化情况与玻璃类型的相关性显著且高度相关($P < 0.01$),与颜色的相关性也有一定程度的显著性($P < 0.05$),而与纹饰的相关性最低,不显著.该结果与折线图分析结果一致.

表1 文物风化情况与各个影响因子相关系数

	纹饰	类型	颜色	是否风化
纹饰	1.000	0.119	0.321*	-0.037
类型	0.119	1.000	0.562**	-0.344**
颜色	0.321*	0.562**	1.000	0.102
是否风化	-0.037	-0.344**	0.102	1.000

注:*在0.05级别(双尾),相关性显著;**在0.01级别(双尾),相关性显著.

2.1.2 文物样品表面化学成分含量的统计规律

将高钾玻璃分为未风化和风化两类,铅钡玻璃分为未风化、风化和严重风化三类,通过相关性分析和差异性检验,结合成分含量范围,得到高钾玻璃和铅钡玻璃化学成分统计规律(见表2和表3).

表2 高钾玻璃制品化学成分统计规律

	二氧化硅	氧化钾	氧化铝	氧化铜	五氧化二磷
未风化高钾	60.12%~87.05%	5.19%~14.75%	3.13%~11.27%	0.78%~5.14%	0.16%~4.55%
风化高钾	92.35%~96.95%	0.59%~1.01%	0.81%~3.24%	0.84%~3.24%	0.15%~0.61%

表3 铅钡玻璃制品化学成分统计规律

	二氧化硅	氧化铅	氧化钡	氧化铝	氧化钙	五氧化二磷
未风化铅钡	35.05%~75.54%	10.51%~40.04%	0.2%~26.63%	1.47%~14.35%	0.39%~4.29%	0
风化铅钡	13.1%~40.53%	26.62%~71.23%	3.37%~31.29%	0.46%~13.76%	1.12%~5.59%	0.07%~13.27%
严重风化铅钡	3.72%~17.65%	29.95%~60.32%	31.17%~35.49%	1.13%~3.77%	3.01%~3.25%	6.05%~14.58%

分析结果显示,二氧化硅含量显著增加,氧化钾和氧化铝含量显著下降,而氧化铜和五氧化二磷含量保持相对稳定.铅钡玻璃在风化过程中,二氧化硅含量显著下降,氧化铅和氧化钡含量显著上升,氧化铝和氧化钙含量波动,五氧化二磷含量先增加后下降,但其比例持续上升.

2.1.3 风化前化学成分含量预测

对所有化合物进行Spearman相关系数分析(见表4),筛选出与风化程度显著相关的因子(如氧化

钾、氧化锶和五氧化二磷)作为后续分析的输入项.为提高模型的准确性和可靠性,数据处理后,剔除累加化合物成分低于规定值的文物编号15和17,确保分析结果不受异常值影响.

表4 文物风化情况与其化合物含量相关系数

	二氧化硅	氧化钠	氧化钾	氧化钙	氧化镁	氧化铝	氧化铁
是否风化	0.180	0.127	0.441**	0.207	0.068	0.255	0.211
	氧化铜	氧化铅	氧化钡	五氧化二磷	氧化锶	氧化锡	二氧化硫
是否风化	0.170	-0.235	-0.171	-0.260*	-0.322*	0.042	-0.058

注: *在0.05级别(双尾),相关性显著; **在0.01级别(双尾),相关性显著.

结果显示,氧化钾、氧化锶和五氧化二磷与风化情况的相关性最高且显著.对与风化情况相关性较弱的化合物,采用卡方检验分析其风化前后含量差异(见表5).结果显示,除氧化镁、氧化锡、氧化钠和二氧化硫外,其余化合物风化前后含量差异显著($P < 0.05$).

表5 卡方检验所得卡方值及显著性系数

	二氧化硅	氧化钠	氧化钙	氧化镁	氧化铝
卡方值	96	26.626	89.034	54.38	96
渐进显著性(双侧)	0.012	0.114	0.005	0.052	0.012
	氧化铜	氧化铅	氧化钡	氧化锡	二氧化硫
卡方值	89.905	80.762	70.778	8.565	11.441
渐进显著性(双侧)	0.006	0.021	0.028	0.2	0.178

2.2 显著相关的化合物回归分析

2.2.1 建立多元线性回归模型

对与风化高度相关的三种化合物作为因变量,结合与风化相关性较弱的11种化合物作为控制变量,并将采样部位的风化程度作为核心解释变量,建立包含定性变量的多元线性回归方程进行分析.将与风化高度相关的化学物质称为风化物质,与风化相关性较低的化学物质称为一般物质.

因变量:风化物质含量(WT),范围为0~100%.自变量:是否风化(WG),虚拟变量,风化样本记为2,非风化样本记为1;一般物质含量(GT):范围为0~100%.模型流程(见图4)展示了模型的建立过程.

为了分析玻璃制品风化过程中化学成分含量变化,本文构建模型如下:

$$WT_i = \alpha + \sum \beta_n \times GT_j + \lambda \times WG_i + \varepsilon_i, \varepsilon_i \sim N(0, \sigma^2)$$

WT_i 表示玻璃制品中名称为*i*的风化物质含量, GT_j 表示玻璃制品中名称为*j*的一般物质含量, WG_i 是风化程度的虚拟变量, ε_i 是不可观测的随机误差向量, β_n 是回归系数构成向量,是未知待定的常数项.

2.2.2 多元回归模型求解

以高钾类型玻璃风化前的氧化锶含量进行多元回归分析预测为例,利用15个样本的指标值,通过SPSS软件进行求解,得到一般物质含量和风化程度系数对氧化锶的十二元线性回归方程:

$$y = 0.808 - 0.007x_1 - 0.078x_2 - 0.003x_3 - 0.019x_4 - 0.028x_5 + 0.047x_6 + 0.049x_7 - 0.032x_8 + 0.013x_9 - 0.007x_{10} + 0.083x_{11} - 0.098x_{12}$$

公式中的指标含义如下:氧化钙(CaO) x_1 、氧化镁(MgO) x_2 、氧化铁(Fe_2O_3) x_3 、氧化铜(CuO) x_4 、氧化铅(PbO) x_5 、氧化钡(BaO) x_6 、氧化锡(SnO_2) x_7 、氧化钠(Na_2O) x_8 、氧化铝(Al_2O_3) x_9 、二氧化硅(SiO_2) x_{10} 、二

氧化硫(SO_2) x_{11} 、风化程度系数 x_{12} .

2.2.3 回归模型的显著性检验

若证明一般物质含量和风化程度系数与氧化锆含量有着密切关系,就利用统计软件 SPSS 对求解得到的十二元线性回归模型进行显著性检验,结果见表 6.




图4 模型流程图

表6 模型汇总

模型	R	R^2	调整后 R^2	标准估算的误差
1	0.970 ^a	0.940	0.838	0.017 04

从表6可知,复相关系数 $R=0.970$,多重判定系数 $R^2=0.940$;调整后的 $R^2=0.838$.调整后 R^2 的值越大,模型的拟合效果就越好.回归方程的显著性检验见表7.

表7 方差分析表

模型		平方和	自由度	均方	F	显著性
1	回归	0.032	12	0.003	9.200	0.003 ^b
	残差	0.002	7	0.000		
	总计	0.034	19			

由表7各项数据可知: $F=9.200$, $F>F_{0.05}(12,15)=2.62$,回归方程显著,即自变量和因变量之间存在明显的函数关系.回归系数的显著性检验见表8.

表8 回归系数表

模型		未标准化系数		标准化系数	<i>t</i>	显著性
		B	标准误差	Beta		
1	常量	0.808	0.174		4.641	0.002
	氧化钙(CaO)	-0.007	0.003	-0.592	-2.314	0.054
	氧化镁(MgO)	-0.078	0.030	-1.242	-2.567	0.037
	氧化铁(Fe ₂ O ₃)	-0.003	0.006	-0.100	-0.460	0.659
	氧化铜(CuO)	-0.019	0.009	-0.636	-2.135	0.070
	氧化铅(PbO)	-0.028	0.020	-0.321	-1.418	0.199
	氧化钡(BaO)	0.047	0.026	0.885	1.779	0.119
	氧化锡(SnO ₂)	0.049	0.015	0.606	3.146	0.016
	氧化钠(Na ₂ O)	-0.032	0.012	-0.935	-2.609	0.035
	氧化铝(Al ₂ O ₃)	0.013	0.003	0.979	3.824	0.007
	二氧化硅(SiO ₂)	-0.007	0.002	-2.488	-4.680	0.002
	二氧化硫(SO ₂)	0.083	0.115	0.292	0.715	0.498
	风化程度系数	-0.098	0.026	-1.086	-3.723	0.007

表8给出了模型对12个变量的偏回归系数是否等于0的*t*检验结果.*t*值分别等于4.641,-2.314,-2.567,-0.460,-2.135,-1.418,1.779,3.146,-2.690和3.824.大部分概率*P*值小于显著性水平0.05,因此,如果偏相关系数 β 明显不等于0,说明大部分指标和因变量的线性相关显著.

综上,一般物质含量和风化程度系数与氧化锶含量存在密切关系.余下的化学物质多元线性回归方程通过相同方法进行模型求解与检验,可以得到类似结果.表9~表10为3种风化物质的回归系数.

表9 铅钡玻璃相关化合物的回归系数

	常量	氧化钙	氧化镁	氧化铁	氧化铜	氧化铅	氧化钡
氧化钾	-1.012	-0.005	0.133	0.052	-0.013	0.01	0.018
五氧化二磷	60.974	-0.694	-0.214	-0.49	-0.059	-0.6	-0.824
氧化锶	-0.444	-0.032	0.119	-0.002	0.038	0.013	-0.002
	氧化锡	氧化钠	氧化铝	二氧化硅	二氧化硫	风化程度系数	
氧化钾	-0.088	0.005	0.043	0.005	0.009	0.184	
五氧化二磷	0.084	-0.803	-0.595	-0.598	-0.13	-0.622	
氧化锶	-0.017	0.031	0.029	-0.004	0.027	0.225	

表10 高钾玻璃相关化合物的回归系数

	常量	氧化钙	氧化镁	氧化铁	氧化铜	氧化铅	氧化钡
氧化钾	80.464	-0.141	-10.549	-1.359	-2.132	-3.975	5.367
五氧化二磷	2.798	-0.231	-0.369	0.4	0.191	0.011	-0.663
氧化锶	0.808	-0.007	-0.078	-0.003	-0.019	-0.028	0.047
	氧化锡	氧化钠	氧化铝	二氧化硅	二氧化硫	风化程度系数	
氧化钾	5.668	-1.055	1.197	-0.745	23.266	-6.387	
五氧化二磷	0.29	-0.56	0.31	-0.037	-2.575	0.211	
氧化锶	0.049	-0.032	0.013	-0.007	0.083	-0.098	

加入定性变量的多元回归方程得到了具体的回归系数.将一般物质含量风化前的预测值代入方程,并将控制变量 WG (是否风化)的值置为1(样品未风化),即可得到各个回归方程对应的因变量,即3种风化物质在风化前的含量预测.高钾玻璃预测结果见表11.

表11 高钾玻璃的风化物质含量预测

文物采样点	氧化钾	五氧化二磷	氧化锶
07	19.678 28	2.505 127	0.193 751
09	20.181 05	2.301 658	0.215 795
10	20.446 33	1.909 082	0.222 722
12	20.974 55	2.278 308	0.219 174
22	24.878 73	2.743 297	0.254 616
27	20.965 17	2.572 746	0.223 405

2.3 成分分类思路与分类规律

2.3.1 分类思路

本研究基于“玻璃类型的分布规律”和“化学成分”提出了三种划分思路.但由于缺乏化合物高低标准及参考区间,排除了其中不适用的思路,最终采用化合物含量分级并通过多化合物组合确定类别划分方法.结合聚类分析,进一步细分化学成分类别,实现更精确的分类^[8],具体选择理由如下:

①基于类型分布规律的划分方法虽然直观,但缺乏量化标准,难以处理样本间细微差异;②单一化学成分的含量划分方法过于简化,无法反映多种成分共同作用下的复杂风化机制.③多化合物组合与聚类分析相结合的方法能够综合考虑多个化学成分的影响,提供更加细致和科学的分类结果,适应本研究的大样本量和多维数据特点.因此,最终采用的分类思路不仅克服了前面方法的局限性,还通过多化合物组合和聚类分析的结合,实现了对高钾玻璃和铅钡玻璃更为精确和科学的分类.

2.3.2 分类规律分析

分类前,首先需要分析高钾玻璃和铅钡玻璃的分类规律.聚类分析方法在分类研究中有广泛应用,因此本文采用该方法对玻璃制品进行类型划分.

本研究使用MATLAB工具箱进行数据模拟,并结合文献^[9]设定 P 值,比较多种检验方法的适用性,结果见图5.




图5 各个检验方法的P-VALUE值

对检验方法经过分析,发现配对 T 检验适用于两组差值近似服从正态分布的数据.而当数据不满足正态分布假设时,选择 Wilcoxon 符号秩检验能够有效克服局限性.因此,本文采用非参数统计方法(Wilcoxon 符号秩检验)对玻璃制品的化合物含量进行聚类分析,确保分类结果的可靠性和科学性^[10].本研究的创新之处在于通过结合非参数检验与聚类分析,克服了数据非正态分布的限制,实现了对高钾玻璃和铅钡玻璃更为精准的分类.

2.3.3 数据处理与回归分析

考虑到数据中不同的风化情况(如未风化部分与严重风化部分),所以单纯进行平均值处理会产生一定的误差,因此先对数据进行加权平均值处理: $W_t = \beta W_{t-1} + (1 - \beta)\theta_t$. W_t 表示目前风化程度的各个样本化合物加权平均后的值, W_{t-1} 表示在风化程度的前一个状态的各个样本化合物加权平均后的值, θ_t 表示当前风化程度中各样本化合物加和的平均值. β 表示权值,此处取 0.9.而三个状态分别为未风化、风化、严重风化,在 t (三个状态)的变化中进行指数加权平均处理,最终获得分别代表高钾和铅钡两组玻璃制品配对的数据.

2.3.4 Wilcoxon 符号秩检验分析

在对高钾和铅钡两组玻璃制品的数据进行指数加权平均处理后,获得了配对数据.随后,应用 Wilcoxon 符号秩检验这两组数据并进行统计分析.首先,对配对差值进行正态性检验,结果见表 12.由于样本量 $N < 5\,000$,采用 Shapiro-Wilk 检验和 Kolmogorov-Smirnov 检验^[11-12].检验结果显示,铅钡指数加权平均值(以下简称铅钡值)与高钾指数加权平均值(以下简称高钾值)的配对样本在 Shapiro-Wilk 检验和 Kolmogorov-Smirnov 检验中均达到显著性水平($P < 0.01$),因此拒绝原假设,表明数据不符合正态分布的假设.

表 12 配对差值正态性检验结果

变量名	样本量	平均值	标准差	偏度	峰度	S-W 检验	K-S 检验
铅钡值	14	0.177	0.327	2.144	3.427		
高钾值	14	0.089	0.263	3.693	13.733		
铅钡值配对高钾值	14	0.088	0.233	3.179	10.625	0.513(0.000***)	0.385(0.023**)

注:***、**、*分别代表 1%、5%、10% 的显著性水平.

由于数据不满足正态分布,采用配对样本 Wilcoxon 符号秩检验进一步分析.检验结果显示,铅钡值与高钾值的配对样本具有显著性差异($P = 0.023^{**}$),Cohen's d 值为 0.298,表明差异具有中等效应量(见表 13).尽管两者存在显著性差异,但具体化学成分的变化仍存在一定的不确定性,因此在配对样本 Wilcoxon 检验之后,加入决策树模型来确定各个化学成分的具体占比,从而分析出高钾玻璃与铅钡玻璃的化合物分类规律.

表 13 配对样本 Wilcoxon 符号秩检验

配对变量	中位数±标准差			Z 值	自由度	P 值	Cohen's d
	配对 1	配对 2	配对差值				
铅钡值配对高钾值	0.034±0.327	0.009±0.263	0.012±0.233	2.271	13	0.023**	0.298

注:***、**、*分别代表 1%、5%、10% 的显著性水平.

2.3.5 决策树模型的建立与分类

以高钾制品与铅钡制品的化学成分为基础,建立决策树分类模型,确定各化学物质的重要性占比.本研究采用基尼系数作为决策树分裂标准,其计算公式: $\text{gini}(T) = 1 - \sum p_i^2$.

当引入某个用于分类的变量(如“满意度<5”)时,分类后的基尼系数公式如下:

$$\text{gini}(T) = \frac{S_1}{S_1 + S_2} \text{gini}(T_1) + \frac{S_2}{S_1 + S_2} \text{gini}(T_2),$$

其中 S_1 、 S_2 为划分后各自的样本量, $\text{gini}(T_1)$ 、 $\text{gini}(T_2)$ 为两类各自的基尼系数.

通过建立的决策树来计算特征重要性,结果见表14、表15.

表 14 高钾制品化合物重要性占比

自变量	重要性	正态化重要性
二氧化硅(SiO_2)	0.420	100.0%
氧化铁(Fe_2O_3)	0.420	100.0%
氧化钙(CaO)	0.420	100.0%
氧化钾(K_2O)	0.420	100.0%
氧化铝(Al_2O_3)	0.327	77.8%
氧化镁(MgO)	0.322	76.7%
五氧化二磷(P_2O_5)	0.210	50.0%

表 15 铅钡制品化合物重要性占比

自变量	重要性	正态化重要性
氧化锡(SnO_2)	0.390	100.0%
五氧化二磷(P_2O_5)	0.086	22.1%
二氧化硅(SiO_2)	0.082	21.0%
氧化铁(Fe_2O_3)	0.059	15.2%
氧化镁(MgO)	0.057	14.7%
氧化钙(CaO)	0.029	7.3%
氧化铜(CuO)	0.028	7.1%
氧化钾(K_2O)	0.020	5.1%
氧化钠(Na_2O)	0.010	2.6%
氧化锶(SrO)	0.008	2.2%
氧化钡(BaO)	0.008	2.1%
氧化铅(PbO)	0.006	1.6%
氧化铝(Al_2O_3)	0.000	0.1%

通过结合 Wilcoxon 符号秩检验与决策树模型中的化合物重要性占比,并参考风化过程中的化学变化,得出如下结论:①高钾玻璃中二氧化硅、氧化铁、氧化钙和氧化钾占比较大,这些化合物在风化过程中的变化对风化程度有显著影响;②铅钡玻璃中氧化锡占主导,其变化显著影响风化情况.

分类规律显示:高钾玻璃的氧化钙、氧化铁、氧化铜、氧化钾含量高于铅钡玻璃,二氧化硅含量明显高于铅钡玻璃,氧化铝和五氧化二磷含量也存在较大差异;铅钡玻璃的氧化铅和氧化钡含量远高于高钾玻璃,这些差异源于不同的制作工艺和原材料.通过指数加权平均数和决策树模型,本研究得出

了高钾玻璃与铅钡玻璃的分类规律(见图6)。




图6 高钾玻璃与铅钡玻璃分类规律

2.3.6 K均值聚类模型建立

使用SPSS软件,依据决策树模型所得到重要性占比较大的化合物对各个样本取样点进行K均值(K-means)聚类分析(高钾玻璃与铅钡玻璃分别进行),以使化合物含量比例相似的样本被划分至一类中,总计得到K个不同类别.经过多次试验,发现当K过小或过大时,容易出现类内评分均值在类间相近、聚类出的样品过于集中,无法为不同的样品赋予不同的类别与排序.由此,根据聚类分析的实际情况,取 $K=3$,根据决策树模型得到的化合物重要程度指标,得到聚类分析的划分结果.

对高钾玻璃与铅钡玻璃进行聚类分析之后,进行可视化处理,使不同的样本在不同类别中可以表现得更为清晰直接,划分结果所对应的饼状图(见图7、图8)。




图7 高钾玻璃分类




图8 铅钡玻璃分类

2.3.7 合理性分析

进行聚类分析之后,高钾玻璃与铅钡玻璃分别分为三类,而样本则被划分到相应的类别中.进行合理性分析需要将每个样本所对应的化合物含量方程罗列出来,并放入折线图进行趋势比较.如果每个类别的曲线趋势大致相同并保持相同比例,就说明聚类模型所得结果是合理的.

高钾玻璃的合理性分析:通过MATLAB代码绘图得到高钾玻璃整体的曲线趋势以及通过聚类划分的三个类别的曲线,观测曲线的平稳运动趋势以及符合实验结果的曲线数量(见图9~图12)。




图9 高钾玻璃(总)的化学物质曲线




图10 高钾玻璃(第一类)的化学物质曲线




图11 高钾玻璃(第二类)的化学物质曲线




图12 高钾玻璃(第三类)的化学物质曲线

铅钡玻璃的合理性分析:通过 MATLAB 代码绘图得到铅钡玻璃整体的曲线趋势以及通过聚类划分的三个类别曲线,观测曲线的平稳运动趋势以及符合实验结果的曲线数量。




图13 铅钡玻璃(总)的化学物质曲线




图14 铅钡玻璃(第一类)的化学物质曲线




图15 铅钡玻璃(第二类)化学物质曲线




图16 铅钡玻璃(第三类)化学物质曲线

从图可看出,不同类别的具体聚类划分曲线趋势呈大致相同特征,从而证明聚类模型的合理性.

2.3.8 敏感性分析

在对高钾玻璃和铅钡玻璃选择合适化学成分进行聚类划分后,根据决策树模型对化合物成分的重要性进行排序,并将重要性较低的成分加入聚类分析并对敏感性进行测试.初始聚类成分包括SiO₂、Fe₂O₃、CaO、K₂O、Al₂O₃和MgO.通过先后去除MgO和替换Al₂O₃为P₂O₅,进行了两次聚类分析,结果见表16.

表 16 高钾玻璃敏感性分析

	第一类	第二类	第三类
聚类分析(文物编号)	7,9,10,12,22,27	3,18,21	1,4,5,6,13,14,15,16,17
敏感性分析一(文物编号)	7,9,10,12,22,27	3,18,21	1,4,5,6,13,14,15,16,17
敏感性分析二(文物编号)	7,9,10,12,22,27	3,18,21	1,4,5,6,13,14,15,16,17

通过三次聚类结果可得结论:每一次的聚类划分化合物成分尽管发生了改变,但总体的划分情况相同,并且三次聚类中心仅第三次的Ⅲ类中心从6.125转变为6.131,说明对高钾玻璃的聚类模型有着极强的稳定性.

铅钡玻璃的敏感性分析:由决策树模型可以得到铅钡制品化合物重要性占比,而铅钡玻璃类型的聚类分析是通过分析化合物SnO₂、P₂O₅、SiO₂、Fe₂O₃得到聚类划分,此时对聚类进行灵敏度分析,修改参与聚类的化合物成分并观测最终分类结果是否稳定.

在初始的化合物组合中加入氧化镁(MgO)并再次进行聚类分析,此时参与聚类的化合物成分为SnO₂、P₂O₅、SiO₂、Fe₂O₃、MgO,得到结果后同时观察聚类中心的变动是否在一定范围内.

将三氧化二铁(Fe₂O₃)去掉进行聚类分析,此时参与聚类的化合物成分为SnO₂、P₂O₅、SiO₂,得到结果后同时观察聚类中心的变动是否在一定范围内,结果如表17.

表 17 铅钡玻璃敏感性分析

	第一类	第二类	第三类
聚类分析 (文物编号)	23, 25, 28, 29, 31, 32, 33, 35, 37, 42, 44, 45, 46, 47, 48, 53, 55	8, 26, 39, 40, 41, 43, 51, 52, 54, 57	2, 11, 19, 20, 24, 30, 34, 36, 38, 49, 50, 56, 58
敏感性 分析一	23, 25, 28, 29, 31, 32, 33, 35, 37, 42, 44, 45, 46, 47, 48, 53, 55	8, 26, 39, 40, 41, 43, 51, 52, 54, 57	2, 11, 19, 20, 24, 30, 34, 36, 38, 49, 50, 56, 58
敏感性 分析二	23, 25, 28, 29, 31, 32, 33, 35, 37, 42, 44, 45, 46, 47, 48, 53, 55	8, 26, 39, 40, 41, 43, 51, 52, 54, 57	2, 11, 19, 20, 24, 30, 34, 36, 38, 49, 50, 56, 58

通过三次聚类结果可得出:每一次聚类划分,尽管其中的化合物成分发生了改变,但总体划分情况是相同的,并且由于聚类中心不存在变动或者仅有极小幅变动,说明对铅钡玻璃的聚类模型有着较强的稳定性.

2.4 Fisher判别与敏感性评估

2.4.1 Fisher线性判别

Fisher判别方法是根据已有观测样本的若干数量特征对新获得的样本进行识别、预测,判断其所属类型的一种统计分析方法^[13].Fisher判别是在原始样本空间里找到数个方向,并沿着该方向进行样本投影,然后再利用距离判别法进行判别准则建立,继而把样本分开.投影后的样本在新空间中具有尽量大的类间距离与尽量小的类内距离.此时,样本在该空间中有最近的可分离性.

训练样本集 $X = X_1, \dots, X_N$, 每一个样本是一个 d 维向量, 其中 w_1 类的样本 $X_1 = X_{11}, \dots, X_{N11}$, w_2 类的样本 $X_2 = X_{12}, \dots, X_{N12}$. 要寻找一个投影方向 W (W 也是一个 d 维向量), 投影以后的样本变成 $y_i = W^T X_i, i = 1, 2, \dots, N$. 在原样本空间中, 类均值向量为 $m_i = \frac{1}{N_i} \sum_{x_j \in X_i} x_j, i = 1, 2, \dots, N$. 定义各类的类内离散度矩阵为 $S_i = \sum_{x_j \in X_i} (x_j - m_i)(x_j - m_i)^T, i = 1, 2$. 总类内离散度矩阵为 $S_w = S_1 + S_2$. 故类间离散度矩阵为 $S_b = (m_1 - m_2)(m_1 - m_2)^T$. 优化目标是提升类间距离, 减小类内距离, 所以可最大化, 其函数: $\max J(w) = \frac{w^T S_b w}{w^T S_w w}$, 最佳投影方向为 $w^* = S_w^{-1}(m_1 - m_2)$. 进而实行决策规则 $g(x) = w^T x + w_0 \leq 0$, 则 $x \in \begin{cases} w_1 \\ w_2 \end{cases}$.

2.4.2 化学成分分析与判别

Fisher 线性判别分析过程中, 将已经明确类型的玻璃文物放入训练集, 总结出特征并为未知类型文物做训练, 在运行 Fisher 线性判别分析之后, 可获得未知类别玻璃文物的判别类型, 准确性指标略高并且具有一定的合理性, 结果如表 18.

表 18 对未知玻璃制品分析鉴定结果

文物编号	文物类型	属于高钾的概率	属于铅钡的概率
A1	高钾玻璃	0.989 68	0.010 32
A2	铅钡玻璃	0.000 18	0.999 82
A3	铅钡玻璃	0.000 01	0.999 99
A4	铅钡玻璃	0.000 00	1.000 00
A5	铅钡玻璃	0.000 04	0.999 96
A6	高钾玻璃	1.000 00	0.000 00
A7	高钾玻璃	0.999 71	0.000 29
A8	高钾玻璃	0.924 56	0.075 44

在玻璃成分分类与回归模型分析中, 为了将每个类别中不同化学成分含量进行划分, 使用了聚类模型后得到亚类. 把未知类型的玻璃容器进行分析鉴定之后, 可以将文物编号为 A1~A8 的玻璃制品根据其聚类之后到聚类中心的距离进行类型划分, 最终划分结果如表 19 所示.

表 19 类型划分结果

文物编号	A1	A2	A3	A4	A5	A6	A7	A8
类型	高钾	铅钡	铅钡	铅钡	铅钡	高钾	高钾	高钾
亚类类型	Ⅲ	Ⅱ	Ⅲ	Ⅲ	Ⅰ	Ⅰ	Ⅰ	Ⅰ

从表 19 可知, A1, A6, A7, A8 被划分为高钾类型, 并且在亚类的划分中 A1 被分为高钾 Ⅲ 类, 而 A5, A6, A7, A8 被分为高钾 Ⅰ 类; A2, A3, A4, A5 被划分为铅钡类型, 并且在亚类的划分中 A2 被分为高钾 Ⅱ 类, A5 被分为高钾 Ⅰ 类, 而 A3, A4 被分为高钾 Ⅲ 类.

2.4.3 敏感性分析

敏感度分析中将各个文物样本的化合物含量参数正向调整 5% 及 10%, 并在调整后的数值上重新进行 Fisher 判别, 同时在同一平面内呈现各个曲线的趋势, 若曲线趋势相似且调整后仍旧在原分类中, 则可证明模型的鲁棒性. 在增长的百分比下, 三维图像更能反映出曲线的趋势, 通过 MATLAB 模拟所得图形如图 17 所示.

由图 17 可知,将化合物含量参数进行调整仅仅影响其曲线的均值,对曲线的趋势影响极小,故模型具有较好的鲁棒性.

2.5 玻璃化学成分的典型相关与差异分析

2.5.1 典型相关模型建立

在分析不同类别玻璃文物样品的化学成分关联性时,采用典型相关分析法.以铅钡玻璃成分为输入变量,高钾玻璃成分为输出变量,探讨两者的线性组合关系,以揭示其相关性和差异性.

首先,根据表中数据,将铅钡玻璃的化学成分指标设为 $X=(X_1,X_2,\cdots,X_{14})$,高钾玻璃的化学成分指标设为 $Y=(Y_1,Y_2,\cdots,Y_{14})$.由此构建中心化观测数据矩阵 Z ,包含 14+14 个指标及 69 次观测:

$$Z=\begin{bmatrix} X_{1,1} & \cdots & X_{1,14} & Y_{1,1} & \cdots & Y_{1,14} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ X_{69,1} & \cdots & X_{69,14} & Y_{69,1} & \cdots & Y_{69,14} \end{bmatrix}=\begin{pmatrix} X \\ Y \end{pmatrix}_{69\times 14,69\times 14}$$

对原始数据进行标准化处理,计算相关系数矩阵 R .矩阵 R 可分解为 $R=\begin{bmatrix} R_{11} & R_{12} \\ R_{21} & R_{22} \end{bmatrix}$,其中 R_{11} 、 R_{22} 分别为铅钡玻璃和高钾玻璃的化学成分含量指标内的相关系数阵, R_{12} 、 R_{21} 为铅钡玻璃和高钾玻璃的化学成分含量间的相关系数阵.

其次,计算典型相关系数及典型变量.首先解矩阵 $A=R_{11}^{-1}R_{12}R_{22}^{-1}R_{21}$ 的特征根 λ_i^2 ,特征向量 $S_1\alpha_i$; $B=R_{22}^{-1}R_{21}R_{11}^{-1}R_{12}$ 的特征根 λ_i^2 ,特征向量 $S_2\beta_i$,则有 $\alpha_i=S_1^{-1}(S_1\alpha_i)$, $\beta_i=S_2^{-1}(S_2\beta_i)$.

由此,随机变量铅钡玻璃成分含量指标 X 和高钾玻璃成分指标 Y 的典型相关系数为 λ ,其典型变量为 $\begin{bmatrix} V_1=\alpha_1'X \\ W_1=\beta_1'Y \end{bmatrix}, \begin{bmatrix} V_2=\alpha_2'X \\ W_2=\beta_2'Y \end{bmatrix}, \cdots, \begin{bmatrix} V_t=\alpha_t'X \\ W_t=\beta_t'Y \end{bmatrix} (t\leq 55)$.

最后,进行典型相关系数的显著性检验^[20].在对铅钡玻璃理化指标 X 和高钾玻璃理化指标 Y 进行典型相关分析前,需首先检验两组变量是否相关.若二者无相关性(即 $\text{cov}(x,y)=0$),则讨论两组变量的典型相关就毫无意义.

2.5.2 典型相关分析及显著性检验

对两种类型的数据进行典型相关分析,提取 3 对典型的相关变量,得出 3 个典型相关系数,分别是 1.000、0.731、0.684.在总体系数是否为 0 的假设性检验中,第 11 个典型相关系数满足显著性要求 ($P<0.05$),意味着 X 和 Y 两组分析项之间有着紧密的正向相关关系,即两种类型的玻璃化学成分之间存在着显著相关关系.




图 17 文物类别划分敏感性分析

表 20 相关数值的典型相关分析

典型变量对	典型相关系数	特征值	Wilks	模型自由度	误差自由度	F	P
第 11 对	1	1	0	25	1.502	177.784	0.006***
第 12 对	0.731	0.534	0.156	16	3.693	0.193	0.993
第 13 对	0.684	0.468	0.336	9	5.018	0.316	0.937

注:***、**、*分别代表 1%、5%、10% 的显著性水平.

结合典型相关系数,运用SPSS 软件计算得出 11 对典型相关模型,将其中第十一对典型相关模型进行提取并转换的多项式为:

$$V_{11}=0.594y_1-65.539y_2+0.117y_3-815y_4-10.141y_5-1.599y_6+0.255y_7+1.785y_8-0.075y_9+0.529y_{10}+3.096y_{11}+0.679y_{12}-1.468y_{13}-0.355y_{14}.$$

$$U_{11}=0.356x_1-0.513x_2+2.298x_3-0.725x_4-0.725x_5-0.514x_6-0.272x_7-0.829x_8-0.624x_9-9.979x_{10}-2.518x_{11}-1.542x_{12}-0.047x_{13}-0.255x_{14}.$$

根据典型相关模型,第一对典型变量中, U_1 主要由铅钡氧化锡、氧化镁和氧化钾主导,典型系数分别为-9.979、2.298 和-1.542,其中铅钡氧化锡最具主导性; V_1 由高钾氧化锶和二氧化硫主导,系数为-65.539 和-10.141.由于铅钡氧化锡和氧化钾的系数为负且高钾氧化锶的系数差异明显,结合分类与回归模型的分析可知,铅钡玻璃中氧化锡占重要地位,高钾玻璃中氧化钾含量较高.这较好地反映了不同类型玻璃在化学成分上的关联性.

2.5.3 差异性分析与结论

根据典型相关模型,铅钡玻璃的化学成分如氧化锡、氧化铁、氧化锶与高钾玻璃中的氧化钡、氧化钠、氧化铜等成分具有显著相关性.不同类型的玻璃化学成分在相关关系上既存在共性,也存在差异性,说明玻璃样品分类的实际意义.

表 21 典型载荷系数和交叉载荷系数

变量	典型变量 X11	典型变量 Y11	变量	典型变量 X11	典型变量 Y11
铅钡氧化钙	-0.168 69	-0.168 69	高钾氧化铜	0.282 877	0.282 877
铅钡氧化铝	-0.052 94	-0.052 94	高钾氧化锶	-0.072 18	-0.072 18
铅钡氧化镁	0.020 476	0.020 476	高钾二氧化硅	0.054 642	0.054 642
铅钡氧化铁	-0.371 02	-0.371 02	高钾氧化钡	0.482 917	0.482 917
铅钡氧化钠	-0.214 79	-0.214 79	高钾二氧化硫	0.141 344	0.141 344
铅钡二氧化硫	0.126 647	0.126 647	高钾氧化锡	-0.106 8	-0.106 8
铅钡二氧化硅	0.009 685	0.009 685	高钾五氧化二磷	0.124 021	0.124 021
铅钡氧化铜	0.01 285	0.012 85	高钾氧化铅	0.291 437	0.291 437
铅钡五氧化二磷	0.254 624	0.254 624	高钾氧化铝	0.138 351	0.138 351
铅钡氧化锡	-0.423 51	-0.423 51	高钾氧化铁	0.089 494	0.089 494
铅钡氧化锶	-0.297 4	-0.297 4	高钾氧化镁	0.245 453	0.245 453
铅钡氧化钾	0.182 029	0.182 029	高钾氧化钾	-0.174 79	-0.174 79
铅钡氧化钡	0.044 941	0.044 941	高钾氧化钠	-0.378 94	-0.378 94
铅钡氧化铅	-0.136 31	-0.136 31	高钾氧化钙	0.016 053	0.016 053

表 21 显示,铅钡玻璃和高钾玻璃的化学成分存在显著差异.铅钡玻璃中,氧化锡、氧化铁和氧化锶尤为重要,且与铅钡样品表面化学成分高度相关;而高钾玻璃中,氧化钡、氧化钠、氧化铅和氧化铜含量更高,对高钾样品表面化学成分影响显著.

3 结论

通过多种统计分析方法,不仅验证了传统分类方法,还揭示了微量成分在不同风化程度下的变化规律.本研究丰富了玻璃风化机制的理论理解,量化了化学成分变化规律,为风化过程的预测和分类提供了新思路,也为古代玻璃文物的保护与修复策略提供了科学依据,并为文化遗产的进一步研究奠

定了坚实的理论基础.

参考文献:

- [1] CHEN Y, YANG Y, ZHANG X, et al. Research Methods for Classification and Identification of Ancient Glass Types[J]. Advances in Computer, Signals and Systems, 2023, 7(11).
- [2] 吴慧. 中国古陶瓷的研究历程(1900–1982)[D]. 长春: 吉林大学, 2022.
- [3] SCHAEFER A, SCOLARO P T, GHISI E. Cluster analysis applied to obtaining reference models for building thermal performance studies[J]. Journal of Building Engineering, 2024, 89.
- [4] 贾晓芬, 郭永存, 黄友锐, 等. 基于斯皮尔曼等级相关性的彩色图像椒盐噪点检测算法[J]. 中国科学技术大学学报, 2019, 49(1): 63–70.
- [5] KANG K, WU W, HE X. Classification Model of Ancient Glass Artifacts Using Fisher Discriminant Analysis[J]. Academic Journal of Computing & Information Science, 2023, 6(7).
- [6] MICHAEL C. The classic texts of Glass Technology – European Journal of Glass Science and Technology Part A [J]. Society of Glass Technology, 2013, 54(2): 57–65.
- [7] HAN Y, D. A H. A robust Spearman correlation coefficient permutation test [J]. Communications in Statistics – Theory and Methods, 2024, 53(6): 2141–2153.
- [8] ALDIN A Z, SALAH D, IYAD M A. Clustering-based method for big spatial data partitioning[J]. Measurement: Sensors, 2023, 27.
- [9] 邱强, 方雷, 姚晓, 等. 基于空间聚类的矢量空间数据并行计算划分方法[J]. 高技术通讯, 2015, 25(4): 327–333.
- [10] JIANG J, ZHANG X, YUAN Z. Feature selection for classification with Spearman's rank correlation coefficient-based self-information in divergence-based fuzzy rough sets[J]. Expert Systems With Applications, 2024, 249.
- [11] ALDIN A Z, SALAH D, IYAD M A. Clustering-based method for big spatial data partitioning [J]. Measurement: Sensors, 2023, 27.
- [12] GARREN T S, DAVENPORT H G. Using Kurtosis for Selecting One-Sample T-Test or Wilcoxon Signed-Rank Test [J]. Current Journal of Applied Science and Technology, 2022, 46–55.
- [13] JIE W. The adoption of repeated measurement of variance analysis and Shapiro-Wilk test [J]. Frontiers of medicine, 2022, 16(4): 659–660.
- [14] 谢纪刚, 裘正定. 非平衡数据集 Fisher 线性判别模型[J]. 北京交通大学学报, 2006, (5): 15–18.

Research on the Composition of Ancient Weathered Glass Based on Multivariate Mathematical Modeling and Data Analysis

XIONG Qiang¹, ZHANG Hanwen², ZHANG Hongjun¹, FANG Qixuan²

(1. School of Communications and Information Engineering, Nanjing University of Posts and Telecommunications, Nanjing 210003, China; 2. School of Internet of Things, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

[Abstract] Various mathematical modeling methods including correlation analysis, multiple linear regression and cluster analysis were applied to study high-potassium glass and lead-barium glass samples under different weathering conditions in the present article. The research investigated the patterns of chemical composition changes during the weathering process. Robustness of the analysis results was ensured through multiple cross-validation methods, such as Spearman correlation analysis, Wilcoxon signed-rank test, and Fisher discriminant analysis. The results indicated that in high-potassium glass, the silicon dioxide content increases while the potassium oxide and aluminum oxide contents decreased during weathering. In lead-barium glass, the lead oxide and barium oxide contents increased while the silicon dioxide content decreased. These findings provided a reference for the identification and preservation of ancient glass artifacts, and the established models demonstrated good predictive accuracy and robustness.

[Key words] Correlation analysis; Decision tree; K-means cluster analysis; Canonical correlation analysis; Multiple method cross-validation

(责任编辑 朱兴红)