

深度学习的统计学习框架

第 1 讲：学习问题、数据表示与学习任务

范一苇

北京理工大学

学习目标

本讲要求：

- ① 概括统计学习的基本问题；
- ② 区分对象、实例、变量、特征与标签；
- ③ 用向量、矩阵和张量表示不同数据；
- ④ 根据可用信息辨别学习任务；
- ⑤ 从模型空间理解深度模型的基本形式。

本讲不涉及具体损失函数与参数估计算法。

统计学习

定义 1 (统计学习)

统计学习研究如何基于数据构建概率统计模型，并用于分析与预测。

统计学习不以记忆样本为目标，而是识别**可复现、可推广的统计规律**。

- 用随机变量与概率分布描述生成机制；
- 用模型表示变量关系；
- 从有限样本中确定可用于新数据的模型。

预测与推断

预测 对新输入输出数值、类别、概率、序列等结果。

推断 由有限数据认识变量效应、结构关系与不确定性。

说明

预测关注新数据上的表现；推断关注结论的含义、稳定性与可解释范围。二者可以并行。

本课程以预测建模为主，同时保留概率建模与统计解释视角。

基本数据概念

对象 (object) 被研究的实体，如病人、交易、新闻、图像或语音。

实例 (instance) 对对象的一次观测或记录，是数据集的基本单位。

变量 (variable) 描述对象属性或状态的量，可为连续型、离散型或结构化变量。

特征 (feature) 作为模型输入的变量或输入表示。

标签 (label) 监督学习中的输出变量，也称响应变量。

例 2

信用风险数据中，客户是对象，申请记录是实例，收入、年龄和负债率是特征，是否违约是标签。

向量表示

含 p 个特征的实例可写为列向量

$$x = (x^{(1)} \quad x^{(2)} \quad \dots \quad x^{(p)})^\top \in \mathbb{R}^p.$$

其中, $x^{(j)}$ 表示第 j 个特征; 括号上标表示**特征维度**, 不是幂。

例 3

以身高、体重和年龄描述一个人:

$$x = (172, 65, 20)^\top.$$

说明

向量分量有固定顺序; 交换分量通常会改变含义。

设计矩阵

n 个实例、每个实例含 p 个特征时，设计矩阵为

$$X = \begin{pmatrix} x_1^\top \\ x_2^\top \\ \vdots \\ x_n^\top \end{pmatrix} = \begin{pmatrix} x_1^{(1)} & \cdots & x_1^{(p)} \\ \vdots & \ddots & \vdots \\ x_n^{(1)} & \cdots & x_n^{(p)} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

- 第 i 行 $x_i^\top$: 第 i 个实例;
- 第 j 列: 第 j 个特征的全部观测值;
- n : 样本量; p : 特征维数。

实例轴与特征轴

对 $X \in \mathbb{R}^{n \times p}$:

$$\underbrace{n}_{\text{实例轴}} \times \underbrace{p}_{\text{特征轴}} .$$

按行观察

- 得到一个实例;
- 可逐样本输入模型;
- 行置换通常不改变数据集含义。

按列观察

- 得到一个变量;
- 各列可有不同单位与类型;
- 列置换必须同步修改特征含义。

说明

行轴与列轴承担不同的统计角色。

张量表示

定义 4 (张量表示)

张量是具有一个或多个坐标轴的数值数组。 d 阶张量可写为

$$\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d},$$

其中, n_j 对应一个具有明确含义的坐标轴。

阶数	数学形式	典型含义
0 阶	标量 a	一个数值
1 阶	向量 $x \in \mathbb{R}^p$	一个实例的特征
2 阶	矩阵 $X \in \mathbb{R}^{n \times p}$	一组实例
d 阶	张量 $\mathcal{X} \in \mathbb{R}^{n_1 \times \cdots \times n_d}$	多轴结构化数据

张量的阶

一阶张量




$$x \in \mathbb{R}^d$$

一个索引: x_i

例: 特征向量

二阶张量




$$X \in \mathbb{R}^{H \times W}$$

两个索引: X_{ij}

例: 灰度图像

三阶张量




$$T \in \mathbb{R}^{H \times W \times 3}$$

三个索引: T_{ijc}

例: RGB 彩色图像

图像通道



红、绿、蓝三个 $H \times W$ 矩阵

$$\mathcal{X} \in \mathbb{R}^{3 \times H \times W},$$

$$\mathcal{X}[:, h, w] = (r_{hw}, g_{hw}, b_{hw})^\top.$$

定义 5 (通道)


通道轴索引同一位置的信息类型，长度记为 C 。

- 灰度图像通常 $C = 1$ ；RGB 图像 $C = 3$ ；
- $\mathcal{X}[:, h, w]$ 取位置 (h, w) 的全部通道；
- 冒号 “:” 表示该轴的全部索引；
- 深层通道表示学习到的特征图；

批量维度

定义 6 (批量)

将 B 个同形实例沿新轴堆叠，得到批量张量； B 为批量大小。



以彩色图像为例：

$$\mathcal{X}_b \in \mathbb{R}^{C \times H \times W}, \quad b = 1, \dots, B,$$

$$\mathbf{X} = \text{stack}_{b=1}^B \mathcal{X}_b \in \mathbb{R}^{B \times C \times H \times W}.$$

- $\mathbf{X}[b, :, :, :] = \mathcal{X}_b$: 取出第 b 个实例；
- 通常 $B < n$ ；小批量只含部分数据；
- 变长序列常用填充与掩码统一。

张量形状

数据类型	单个实例的常见形状	一批实例的常见形状
表格记录	(p)	(B, p)
灰度图像	(H, W)	$(B, 1, H, W)$
彩色图像	(C, H, W)	(B, C, H, W)
特征序列	(T, d)	(B, T, d)
音频波形	(T)	(B, T)
视频	(T, C, H, W)	(B, T, C, H, W)

- B : 批量大小; C : 通道数; H, W : 空间尺寸;
- T : 时间或序列长度; d : 每个位置的表示维数。

注意: 轴顺序可能因软件而异, 程序中须明确张量的 shape 约定。

张量与数据结构

图像、序列或视频可拉平为向量，但原有组织关系不再显式。

数据	需要保留的结构	典型关系
图像	空间位置与通道	相邻像素、局部图案
文本与时间序列	顺序与时间位置	前后依赖、长程关联
视频	时间、空间与通道	运动及场景变化
图数据	节点与边	邻接和拓扑关系

模型应适配数据结构；每个张量轴既表示尺寸，也承载建模语义。

结构化输入与输出

监督学习数据常记为

$$\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n.$$

x_i 和 y_i 可为标量、向量或更复杂的结构:

任务	输入 x_i	输出 y_i
房价预测	表格特征向量	实数
图像分类	图像张量	类别标签
图像分割	图像张量	像素级标签矩阵
机器翻译	词元序列	词元序列
多标签识别	图像或特征向量	多标签指示向量

具有顺序、层次、邻接或空间关系的输出称为**结构化输出**。

直接创建

PyTorch 用 `torch.Tensor` 统一表示向量、矩阵与高阶张量：

```
import torch
x = torch.tensor([1.0, 2.0, 3.0]) # vector
A = torch.tensor([[1, 2], [3, 4]], # matrix
                  dtype=torch.float32)
Z = torch.zeros((2, 3))           # all zeros
I = torch.eye(3)                  # identity matrix
grid = torch.arange(12).reshape(3, 4) # integer grid
```

`tensor` 根据给定数据创建张量；其余构造器生成零矩阵、单位矩阵与等间隔整数。`reshape` 只改变形状，不改变元素总数。

接口参考：PyTorch Tensor 文档。

属性检查

创建张量后，首先检查形状、数据类型与所在设备：

```
print("A:", A.shape, A.dtype, A.device)
print("grid:", grid)
```

输出

```
A: torch.Size([2, 2]) torch.float32 cpu
grid: tensor([[ 0,  1,  2,  3],
              [ 4,  5,  6,  7],
              [ 8,  9, 10, 11]])
```

`shape` 每个轴的长度；A 有两个轴，每个轴长度为 2；

`dtype` 元素类型；模型参数通常使用浮点数；

`device` 张量位置；cpu 表示当前位于内存中的 CPU 张量。

随机生成

随机张量可用于模拟数据、初始化参数与调试程序：

```
import torch

torch.manual_seed(7) # make this example reproducible

u = torch.rand((4, 3))      # Uniform[0, 1)
z = torch.randn((4, 3))     # standard Normal
labels = torch.randint(0, 3, (4,)) # class 0, 1, or 2
noise = 0.2 * torch.randn((4, 1)) # scaled noise
```

rand、randn、randint 分别生成均匀、正态与整数随机数据。

随机输出

查看一个特征向量和四个类别标签：

```
print("u[0]:", u[0])          # first sample  
print("labels:", labels)      # four class indices
```

输出（固定随机种子）

```
u[0]: tensor([0.5349, 0.1988, 0.6592])  
labels: tensor([0, 2, 2, 2])
```

- `u[0]` 取批量中的第一个实例，形状由 $(4, 3)$ 变为 (3) ；
- `labels` 含 4 个整数，分别对应 4 个实例；
- 固定随机种子后，重复运行可得到相同输出。

读取表格

假设 CSV 每行是一个实例，前 p 列为特征，最后一列为标签：

```
import numpy as np
import torch

# Read as float32 to match common model parameters
array = np.loadtxt("sample.csv", delimiter=",",
                  skiprows=1, dtype=np.float32)
data = torch.from_numpy(array) # NumPy -> Tensor

X = data[:, :-1] # all rows, feature columns
y = data[:, -1]  # all rows, last column
```

`from_numpy` 与原数组共享内存； X 的形状为 (n, p) ， y 的形状为 (n) 。

接口参考：torch.from_numpy.

表格输出

检查特征、标签的形状以及缺失值数量：

```
print("X:", X.shape, "y:", y.shape)
print("missing:", torch.isnan(data).sum().item())
```

若文件含 150 行数据、4 个特征，则输出为

```
X: torch.Size([150, 4]) y: torch.Size([150])
missing: 0
```

- 第一维 150 是实例数，第二维 4 是特征数；
- 回归标签可保留浮点类型；分类标签通常转换为 `y.long()`；
- 缺失值不应直接送入模型，应先定位并处理。

读取图像

图像尺寸可能不同，读取后先统一到 224×224 :

```
import torch
from torchvision.io import decode_image
from torchvision.transforms.v2.functional import resize

paths = ["cat.jpg", "dog.jpg"]
images = []
for path in paths:
    image = decode_image(path, mode="RGB") # (C,H,W)
    image = resize(image, [224, 224])      # same H,W
    images.append(image.float() / 255)     # [0,1]

batch = torch.stack(images, dim=0) # add batch axis
```

`decode_image` 返回 (C, H, W) ; 缩放后, `stack` 在最前面增加批量轴。

图像批量

检查合并后的批量形状与数据类型：

```
print("batch:", batch.shape, batch.dtype)
```

输出

```
batch: torch.Size([2, 3, 224, 224]) torch.float32
```

$B = 2$ 批量含两张图像；

$C = 3$ 红、绿、蓝三个颜色通道；

$H = W = 224$ 每个通道是一幅 224×224 的二维图像。

stack 要求被合并张量的形状完全相同。

随机变量与观测值

大写字母表示随机变量，小写字母表示观测值：

$$X \longrightarrow x_i, \quad Y \longrightarrow y_i.$$

(X, Y) 随机输入与随机输出；

(x_i, y_i) 第 i 个实例的观测值；

$P(X, Y)$ 输入与输出的联合分布；

$P(Y | X)$ 给定输入后输出的条件分布。

说明

数据集包含已实现的样本值；统计模型描述其背后的随机机制。

独立同分布假设

假设 1 (独立同分布抽样)

训练样本与未来样本来自同一未知分布 P ，且训练样本相互独立：

$$(X_i, Y_i) \stackrel{\text{i.i.d.}}{\sim} P(X, Y), \quad i = 1, \dots, n.$$

该假设使训练数据中的规律有可能推广到未来数据。

说明

独立同分布是建模近似。若未来数据的生成机制改变，就会出现分布偏移。

学习任务概览

学习范式	可获得的信息	主要目标
监督学习	输入与对应标签	学习输入到输出的统计关系
无监督学习	只有输入数据	发现分布、结构或潜在表示
半监督学习	少量有标签数据与大量无标签数据	利用无标签数据辅助预测
自监督学习 强化学习	由数据构造训练信号 状态、动作及环境反馈	从大规模无标签数据中学习表示 学习能够获得长期回报的决策策略

多种范式可组合使用，如先自监督预训练，再用少量标签监督微调。

监督学习任务

定义 7 (监督学习)

监督学习根据标注数据 $\{(x_i, y_i)\}_{i=1}^n$ ，学习输入 X 与输出 Y 的统计关系。

任务	输出形式	示例
回归	连续数值或数值向量	房价、温度、风险评分
二分类	两个互斥类别	是否违约、是否患病
多分类	多个互斥类别	图像类别、新闻主题
多标签分类	多个标签可以同时成立	图片中的多个物体
排序	实例或候选项的相对顺序	搜索结果、推荐列表
结构化预测	序列、矩阵、树或图	翻译、分割、序列标注

无监督学习任务

无监督学习只观测输入

$$\mathcal{D}_n = \{x_1, x_2, \dots, x_n\},$$

不使用预先给定的输出标签。

聚类 识别数据中的类别或群体；

降维 用低维表示保留主要变化；

密度估计 描述输入空间中的概率分布；

表示学习 学习可供后续任务使用的表示；

生成建模 学习数据分布并生成新样本。

无监督表示可进一步用于监督学习。

半监督与自监督

半监督学习 标签数量有限，利用无标签数据的分布或结构信息改善监督学习。

自监督学习 由数据构造预测目标，无须人工标签即可学习一般表示。

例 8

文本任务可根据上下文预测被遮盖的词；图像任务可判断两个变换后的图像是否来自同一样本。

说明

自监督学习形式上类似监督学习，但监督信号由数据自动产生。

强化学习

强化学习的数据产生于智能体与环境的持续交互：

$$S_t \longrightarrow A_t \longrightarrow (R_{t+1}, S_{t+1}).$$

S_t 时刻 t 的状态；

A_t 智能体的动作；


R_{t+1} 环境奖励；

策略 根据状态选择动作的决策规则。

强化学习还需处理：

- 奖励的延迟性；
- 探索与利用之间的权衡；
- 策略对未来数据分布的影响。

迷宫示例



一条可能的交互轨迹

状态 S_t 智能体所在格点及周围障碍；

动作 A_t 上、下、左、右移动；

奖励 R_{t+1} 到达终点 +10，撞墙 -1，普通移动 -0.1；

策略 $\pi(a | s)$ 在状态 s 下选择动作 a 的规则或概率。

说明

数据中没有“正确动作”标签。智能体通过试错获得奖励；当前动作改变下一状态，终点奖励还可能延迟出现。

条件分布与决策函数

条件分布的观点

$$P(Y \mid X = x)$$

描述给定输入后输出的可能结果及其概率。

该表述可描述预测不确定性。

决策函数的观点

$$f : \mathcal{X} \rightarrow \mathcal{A}$$

将输入映射为数值、类别、排序或结构化对象。

该表述强调最终预测或决策。

说明

两种表述并不矛盾；决策函数通常可由条件分布导出。

生成式与判别式

生成式建模 学习联合分布 $P(X, Y)$ 或数据生成机制，再得到所需的条件关系。

判别式建模 直接学习条件分布 $P(Y | X)$ 或决策函数 $f(X)$ 。

$$P(Y | X) = \frac{P(Y)P(X | Y)}{P(X)}.$$

说明

判别式建模更直接地服务预测；生成式建模适合描述生成机制、隐变量或数据分布。

模型空间

定义 9 (模型空间)

模型空间，也称假设空间，是允许考虑的候选模型集合。参数化模型常写为

$$\mathcal{F} = \{f_{\theta} : \theta \in \Theta\},$$

其中 Θ 是参数空间。

- $\mathcal{F}$ 给出可选的函数或概率分布；
- θ 确定其中一个具体模型；
- 模型结构体现对数据规律的预先假设，即归纳偏置。

学习过程即根据数据从 $\mathcal{F}$ 中选择模型。

多层复合函数

深度模型通常可写为

$$f_{\theta}(x) = (f_L \circ f_{L-1} \circ \cdots \circ f_1)(x).$$

定义逐层表示

$$z^{(1)} = f_1(x), \quad z^{(2)} = f_2(z^{(1)}), \quad \dots, \quad z^{(L)} = f_L(z^{(L-1)}).$$

最终输出为

$$f_{\theta}(x) = z^{(L)}.$$

多层结构以逐层表示组织复杂关系，并适配图像、序列等数据结构。

小结

- ① 统计学习利用有限数据识别可推广规律；
- ② 向量表示单个实例，矩阵组织多个实例，张量保留多轴结构；
- ③ 每个数据轴都有明确的建模语义；
- ④ 学习任务取决于标签、环境反馈与监督信号来源；
- ⑤ 模型空间规定候选模型，多层复合函数是深度模型的基本形式。

思考题

彩色视频张量形状为 (B, T, C, H, W) 时，各轴分别表示什么？若转换为 $(B, TCHW)$ ，哪些结构不再显式？