

深度学习的统计学习框架

第 3 讲：泛化与模型选择

范一苇

北京理工大学

学习目标

本讲要求：

- ① 区分经验风险、期望风险与测试误差；
- ② 解释样本量和模型复杂度对泛化的影响；
- ③ 理解欠拟合、过拟合与偏差-方差权衡；
- ④ 掌握验证集与交叉验证的模型选择流程。

期望风险

定义 1 (期望风险)

设 $(X, Y) \sim P$ 。对函数 $f: \mathcal{X} \rightarrow \mathcal{A}$, 定义

$$R_{\text{exp}}(f) = \mathbb{E}[L\{Y, f(X)\}] = \int L\{y, f(x)\} \mathrm{d}P(x, y).$$

- 它衡量模型在未来同分布样本上的平均损失;
- 总体分布 P 未知, 因此通常不能直接计算。

两类风险

经验风险是期望风险的样本版本：

$$R_{\text{emp}}(f; \mathcal{D}_n) = \frac{1}{n} \sum_{i=1}^n L\{y_i, f(x_i)\}.$$

风险	计算对象	回答的问题
经验风险	已观测训练样本	对当前样本拟合得怎样？
期望风险	总体分布 P	对未来样本预测得怎样？

训练依赖经验风险，评价关心期望风险。

泛化误差

定义 2 (泛化误差)

对独立同分布样本 $\mathcal{D}_n$ 与函数 f , 定义

$$G(f; \mathcal{D}_n) = R_{\text{exp}}(f) - R_{\text{emp}}(f; \mathcal{D}_n).$$

泛化分析通常控制其绝对值:

$$|R_{\text{exp}}(f) - R_{\text{emp}}(f; \mathcal{D}_n)|.$$

说明

小训练误差不等于小期望风险; 二者差距仍需控制。

固定函数

先固定一个不依赖训练样本的函数 f ，并令

$$Z_i = L\{Y_i, f(X_i)\}, \quad 0 \leq Z_i \leq 1.$$

由于 (X_i, Y_i) 独立同分布， $Z_1, \dots, Z_n$ 也独立同分布，且

$$R_{\text{emp}}(f) = \frac{1}{n} \sum_{i=1}^n Z_i, \quad \mathbb{E}(Z_i) = R_{\text{exp}}(f).$$

因而

$$\mathbb{E}R_{\text{emp}}(f) = R_{\text{exp}}(f).$$

说明

“平均无偏”不等于高概率接近，后者需要集中不等式。

Hoeffding 界

定理 3 (Hoeffding 不等式)

若样本独立同分布, f 固定, 且损失落在 $[0, 1]$, 则

$$\Pr(|R_{\text{emp}}(f) - R_{\text{exp}}(f)| > \varepsilon) \leq 2 \exp(-2n\varepsilon^2).$$

令右侧等于 δ , 可得: 以概率至少 $1 - \delta$,

$$|R_{\text{emp}}(f) - R_{\text{exp}}(f)| \leq \sqrt{\frac{\log(2/\delta)}{2n}}.$$

样本量增大时, 固定函数的经验风险以 $n^{-1/2}$ 的量级趋于稳定。

数值量级

取置信度 $1 - \delta = 0.95$ 。当 $n = 500$ 时,

$$\sqrt{\frac{\log(2/0.05)}{2 \times 500}} \approx 0.061.$$

即固定函数的经验风险与期望风险之差以至少 95% 的概率不超过 0.061。

样本量变化	上界变化	原因
$n \rightarrow 4n$	约缩小为一半	上界为 $O(n^{-1/2})$ 平方根收敛
$n \rightarrow 100n$	约缩小为十分之一	

错误想法

设训练样本为 $\mathcal{D}_n$ ，学习算法输出 $\hat{f}_{\mathcal{D}_n}$ 。一种看似合理的推理是

$$\mathbb{E}_{\mathcal{D}_n} R_{\text{emp}}(f; \mathcal{D}_n) = R_{\text{exp}}(f) \implies R_{\text{emp}}(\hat{f}_{\mathcal{D}_n}) \approx R_{\text{exp}}(\hat{f}_{\mathcal{D}_n}).$$

问题在于：等式只对**预先固定的** f 成立。对数据选出的 $\hat{f}_{\mathcal{D}_n}$ ，

$$Z_i = L\{Y_i, \hat{f}_{\mathcal{D}_n}(X_i)\}$$

共同依赖整份训练样本，不再具有上述独立同分布结构。

选择偏差

训练集同时用于选模和评估时，训练误差通常偏乐观。

并集界

当 $\mathcal{F}$ 为有限函数类时，对每个候选函数应用 Hoeffding 不等式，再取并集界：

$$\begin{aligned}\Pr \left\{ \sup_{f \in \mathcal{F}} |R_{\text{emp}}(f) - R_{\text{exp}}(f)| > \varepsilon \right\} &\leq \sum_{f \in \mathcal{F}} \Pr \{ |R_{\text{emp}}(f) - R_{\text{exp}}(f)| > \varepsilon \} \\ &\leq 2|\mathcal{F}|e^{-2n\varepsilon^2}.\end{aligned}$$

令 $2|\mathcal{F}|e^{-2n\varepsilon^2} = \delta$ ，得到

$$\varepsilon = \sqrt{\frac{\log(2|\mathcal{F}|/\delta)}{2n}}.$$

一致界

定理 4 (有限函数类的一致泛化界)

设 $\mathcal{F}$ 为有限函数类, 且所有损失均落在 $[0, 1]$ 。则以概率至少 $1 - \delta$,

$$\sup_{f \in \mathcal{F}} |R_{\text{emp}}(f) - R_{\text{exp}}(f)| \leq \sqrt{\frac{\log(2|\mathcal{F}|/\delta)}{2n}}.$$

解决的问题

一致界同时控制全部候选函数, 因此允许算法再根据数据选择 $\hat{f}_{\mathcal{D}_n} \in \mathcal{F}$ 。

ERM 保证

令经验风险最小化模型与类内最优模型分别为

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} R_{\text{emp}}(f), \quad f_{\mathcal{F}}^* \in \arg \min_{f \in \mathcal{F}} R_{\text{exp}}(f).$$

在一致界成立的事件上,

$$\begin{aligned} R_{\text{exp}}(\hat{f}) &\leq R_{\text{emp}}(\hat{f}) + \varepsilon && \text{(一致界)} \\ &\leq R_{\text{emp}}(f_{\mathcal{F}}^*) + \varepsilon && \text{(ERM)} \\ &\leq R_{\text{exp}}(f_{\mathcal{F}}^*) + 2\varepsilon && \text{(一致界)}. \end{aligned}$$

复杂度作用

泛化界包含三个因素：

$$\sqrt{\frac{\log(2|\mathcal{F}|/\delta)}{2n}}.$$

样本量 n 越大，经验风险越接近期望风险；

函数类 $|\mathcal{F}|$ 越大，同时控制所有候选函数越困难；

置信度 $1 - \delta$ 要求越高，上界越宽。

对无限函数类， $|\mathcal{F}|$ 被 VC 维、Rademacher 复杂度等容量指标替代。

正则化视角

正则化为经验风险加入复杂度代价：

$$\min_{f \in \mathcal{F}} \{R_{\text{emp}}(f) + \lambda \Omega(f)\}.$$

其中 $\Omega(f)$ 衡量复杂度， λ 控制复杂度代价。

核心解释

正则化缩小有效搜索范围，使经验风险更可能代表期望风险。

三类正则化

类型	惩罚项 Ω	主要作用
ℓ_2 惩罚	$\ \theta\ _2^2 = \sum_j \theta_j^2$	连续压缩参数, 抑制过大的系数
ℓ_1 惩罚	$\ \theta\ _1 = \sum_j \theta_j $	产生稀疏参数, 可用于变量选择
平滑惩罚	$\int \{f''(t)\}^2 dt$	抑制函数的剧烈弯曲

λ 越大, 对低复杂度模型的偏好越强。

惩罚与约束

正则化可写为惩罚形式：

$$\min_{f \in \mathcal{F}} \{R_{\text{emp}}(f) + \lambda \Omega(f)\}.$$

也可写为约束形式：

$$\min_{f \in \mathcal{F}} R_{\text{emp}}(f) \quad \text{s.t.} \quad \Omega(f) \leq c.$$

命题 1

在适当条件下，对每个惩罚强度 λ ，存在约束半径 c ，使两种形式具有相同的解；反向也成立。

λ 是复杂度的“价格”， c 是复杂度的“预算”。

测试误差

设独立测试集为

$$\mathcal{D}_{\text{te}} = \{(X_i^{\text{te}}, Y_i^{\text{te}})\}_{i=1}^m.$$

对已训练模型 $\hat{f}$, 测试误差定义为

$$R_{\text{test}}(\hat{f}) = \frac{1}{m} \sum_{i=1}^m L\{Y_i^{\text{te}}, \hat{f}(X_i^{\text{te}})\}.$$

测试集不参与参数拟合、模型比较或超参数选择。

条件无偏性

命题 2

若测试集与模型构造过程独立，并与训练数据来自同一分布，则

$$\mathbb{E}\left[R_{\text{test}}(\hat{f}) \mid \hat{f}\right] = R_{\text{exp}}(\hat{f}).$$

原因是给定 $\hat{f}$ 后，每个测试损失均满足

$$\mathbb{E}\left[L\{Y_i^{\text{te}}, \hat{f}(X_i^{\text{te}})\} \mid \hat{f}\right] = R_{\text{exp}}(\hat{f}).$$


独立性

测试集用途	是否独立	结果
只作最终一次评估	是	可估计期望风险
用于选择超参数	否	测试结果偏乐观
反复查看并修改模型	否	测试集被间接拟合


说明

“没有反向传播到测试集”不等于“没有使用测试集”。只要测试结果影响了模型决策，独立性就已破坏。


三种拟合



欠拟合
结构过于简单




拟合适度
捕捉稳定规律



过拟合
追随样本噪声

合适的复杂度应捕捉稳定规律，而非追随训练噪声。

误差趋势



- **训练误差**随复杂度增加而下降；
- **测试误差**通常先降后升；
- 最低点附近对应较合适的复杂度。

选择目标

关注未知数据误差的低点，而非训练误差最低的模型。

偏差-方差分解

设

$$Y = f_0(X) + \varepsilon, \quad \mathbb{E}(\varepsilon \mid X) = 0, \quad \text{Var}(\varepsilon \mid X) = \sigma^2.$$

对固定输入 x , 平方预测误差可分解为

$$\mathbb{E}[(Y - \hat{f}_{\mathcal{D}}(x))^2 \mid X = x] = \underbrace{(f_0(x) - \mathbb{E}_{\mathcal{D}} \hat{f}_{\mathcal{D}}(x))^2}_{\text{偏差}^2} + \underbrace{\text{Var}_{\mathcal{D}}\{\hat{f}_{\mathcal{D}}(x)\}}_{\text{方差}} + \underbrace{\sigma^2}_{\text{不可约误差}}.$$

偏差与方差

模型	偏差	方差
约束较强、结构简单	通常较大	通常较小
灵活、结构复杂	通常较小	通常较大

偏差 模型对真实函数的系统性偏离；

方差 估计结果对训练样本扰动的敏感性；

不可约误差 数据自身的随机噪声，不能由模型消除。

多项式回归

考虑 M 次多项式函数类

$$f_M(x; w) = \sum_{j=0}^M w_j x^j,$$

其中阶数 M 控制模型复杂度。
在平方损失下，参数估计为

$$\hat{w}_M \in \arg \min_w \frac{1}{n} \sum_{i=1}^n \{y_i - f_M(x_i; w)\}^2.$$

当 M 增大，函数类嵌套扩张，因此训练误差不会上升；测试误差则未必单调下降。

阶数比较

假设真实规律近似二次函数。

$M = 1$	$M = 2$	$M = 9$
只能拟合直线 稳定结构未学全 训练误差较高	能表达二次曲线 与真实结构匹配 训练、测试误差较 低	可形成剧烈弯曲 紧贴训练点与噪声 训练误差很低
欠拟合	拟合适度	过拟合风险较高


多项式阶数是模型结构的一部分，不能只用训练误差选择。

模型选择

模型选择包括模型类型、结构和超参数的选择。

层次	例子
模型类型	线性模型、树模型、神经网络
模型结构	多项式阶数、网络深度与宽度
正则化	惩罚类型与参数 λ
训练过程	学习率、批量大小、早停轮数
输入表示	特征集合、预处理方案

三类数据



评估流程

- ① 划分训练集、验证集与测试集；
- ② 在训练集上拟合每个候选模型；
- ③ 在验证集上比较模型与超参数；
- ④ 确定方案后，用训练集和验证集重新拟合；
- ⑤ 在测试集上作一次最终评估。

说明

是否重新拟合应预先写入实验协议。

验证集选择

设 $m \in \mathcal{M}$ 表示候选模型或超参数设定。在训练集上得到 $\hat{f}_m$ ，并计算

$$\hat{R}_{\text{val}}(\hat{f}_m) = \frac{1}{n_{\text{val}}} \sum_{i=1}^{n_{\text{val}}} L\{y_i^{\text{val}}, \hat{f}_m(x_i^{\text{val}})\}.$$

选择规则为

$$\hat{m} \in \arg \min_{m \in \mathcal{M}} \hat{R}_{\text{val}}(\hat{f}_m).$$

选择例子

假设在训练集上拟合四个正则化强度：

λ	训练损失	验证损失
0	0.12	0.31
0.01	0.14	0.24
0.10	0.18	0.20
1.00	0.29	0.32

应选择 $\lambda = 0.10$ ，而不是训练损失最低的 $\lambda = 0$ 。

K 折交叉验证

将建模数据划分为 K 个互不相交的子集

$$D_1, \dots, D_K.$$

第 k 次用 $D \setminus D_k$ 拟合, 在 D_k 上验证:

$$\widehat{\text{CV}}_K = \frac{1}{K} \sum_{k=1}^K \widehat{R}_{\text{val}}^{(k)}.$$

每个样本恰好作为一次验证样本。



蓝色: 训练折

橙色: 验证折

交叉验证流程

对每个候选模型 m :

- ① 固定同一组 K 个数据折;
- ② 重复 K 次训练与验证;
- ③ 计算平均验证误差 $\widehat{CV}_K(m)$;
- ④ 比较候选模型并选择最优设定;
- ⑤ 在全部训练数据上重新拟合。

数据泄漏

定义 5 (数据泄漏)

训练或模型选择过程使用了部署时不可获得的信息，或使用了验证集、测试集中的信息。

后果

验证误差或测试误差被系统性低估，模型上线后的表现可能明显下降。

泄漏不一定直接使用标签；利用测试集的均值、方差或特征分布也可能构成泄漏。

泄漏场景

错误做法	正确做法
用全部数据估计标准化参数	只在训练集估计，再应用到其余数据
用测试集选择特征或阈值	在训练集或验证集完成选择
多次查看测试结果后修改模型	冻结方案后只评估一次
交叉验证前先对全数据预处理	在每个训练折内部重新拟合预处理

预处理也属于训练流程，必须在训练数据内部拟合。

小结

- ① 期望风险刻画总体表现，经验风险来自有限样本；
- ② 泛化界连接样本量、函数类复杂度与风险偏差；
- ③ 测试误差只有在独立条件下才能估计期望风险；
- ④ 模型复杂度体现为偏差与方差的权衡；
- ⑤ 验证集和交叉验证用于选择，测试集只用于最终报告。

全章主线

任务 → 模型空间 → 学习准则 → 泛化与选择.